

面向智慧交通的邻道干扰排除 与车型分类方法研究

作者姓名 _____ 向倪竺 _____

指导教师姓名、职称 _____ 毛国强 教授 _____

申请学位类别 _____ 工学硕士 _____

学校代码 10701
分类号 TN95

学号 21011210013
密级 公开

西安电子科技大学

硕士学位论文

面向智慧交通的邻道干扰排除 与车型分类方法研究

作者姓名：向倪竺

一级学科：信息与通信工程

二级学科（研究方向）：通信与信息系统

学位类别：工学硕士

指导教师姓名、职称：毛国强 教授

学 院：通信工程学院

提交日期：2024 年 4 月

Research on Adjacent Lane Interference Elimination and Vehicle Classification Method for Intelligent Transportation

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Information and Communications Engineering

By
Nizhu Xiang
Supervisor: Guoqiang Mao Title: Professor
April 2024

西安电子科技大学 学位论文独创性 (或创新性)声明

秉承学校严谨的学风和优良的科学道德,本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知,除了文中特别加以标注和致谢中所罗列的内容以外,论文中不包含其他人已经发表或撰写过的研究成果;也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同事对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文若有不实之处,本人承担一切法律责任。

本人签名: _____ 日 期: _____

西安电子科技大学 关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定,即:研究生在校攻读学位期间论文工作的知识产权属于西安电子科技大学。学校有权保留送交论文的复印件,允许查阅、借阅论文;学校可以公布论文的全部或部分内容,允许采用影印、缩印或其它复制手段保存论文。同时本人保证,结合学位论文研究成果完成的论文、发明专利等成果,署名为西安电子科技大学。

保密的学位论文在____年解密后适用本授权书。

本人签名: _____ 导师签名: _____

日 期: _____ 日 期: _____

摘要

在当前城市交通快速发展的背景下，智慧交通系统（Intelligent Transportation System, ITS）作为推动交通管理的关键因素，受到了广泛关注。随着智能感知技术的不断进步，地磁传感器作为车辆检测的关键组成部分，承担着监测交通流量、保障道路安全和改善交通效率的重要任务。智慧交通系统的运行依赖于实时获取的车辆交通信息，然而在双车道交通场景下，相邻车道的车辆会对地磁传感器所在目标车道的车辆检测产生干扰。为了解决这个问题，需要设计创新的邻道干扰排除算法，以提高地磁传感器在车辆检测中的准确性和可靠性。此外，获取车型信息能够使智慧交通系统更全面地了解道路上不同类型车辆的分布和行为，为城市规划和资源分配提供策略指导。为了给城市交通管理提供更科学、更精细的数据支持，亟需对车流量和车型进行准确检测。本文对相关技术进行研究和分析，提出了基于地磁传感器的邻道干扰排除和车型分类方法，并通过实验验证了该方法的准确性。本文主要工作如下：

一方面，本文在设计面向正常车流密度的状态机车辆检测算法的基础上，研究了双车道交通场景下的邻道干扰问题。针对在双车道一侧车道线上部署地磁传感器的场景，相邻车道的车辆会影响车辆检测算法的高精准检测，导致无法准确地获取目标车道交通流量信息的问题，提出了双车道交通场景下邻道干扰排除算法。首先，从车辆结构出发介绍并分析了车辆的等效磁偶极子模型，设计了多磁偶极子扩展目标模型，并通过差分进化算法确定了模型参数。其次，从模型仿真和理论角度对目标车道车辆和相邻车道车辆磁场扰动的一阶差分波形进行分析，提取了用于邻道干扰排除的磁场特征。然后，基于提取的磁场特征，本文设计了投票机制，以实现双车道交通场景下的邻道干扰排除。最后，通过实际数据测试验证了双车道交通场景下邻道干扰排除算法的检测精度，实验结果表明该算法能够有效提高目标车道车辆检测的精度。

另一方面，在能够准确获取目标车道车辆数的基础上，针对车型分类问题，提出了车型分类算法。首先，地磁传感器采集到的三轴磁场数据通常同时受到环境磁场和车辆引起的磁场扰动的影响，为了提取车辆引起的磁场扰动，本文设计了地磁环境基线更新方法，通过将采集到的原始磁场数据减去地磁环境基线，获得车辆引起的磁场扰动。其次，分析不同车辆类型引起的磁场扰动波形，提取车型分类特征，并使用特征配对消除的筛选算法对特征进行筛选。然后，利用筛选的特征集，本文设计了基于SoftMax回归的车型分类算法。最后，通过实际数据检测了车型分类算法的精度，实验结果表明该算法能够高精度地识别车辆类型。

关键词：地磁传感器， 磁偶极子建模， 邻道干扰， 车型分类

ABSTRACT

In the context of the rapid development of urban transportation, the Intelligent Transportation System (ITS) has received extensive attention as a key factor in promoting traffic management. Geomagnetic sensors are a crucial component of vehicle detection. With the continuous advancement of intelligent sensing technology, geomagnetic sensors undertake the crucial tasks of monitoring traffic flow, ensuring lane safety, and enhancing traffic efficiency. The operation and management of intelligent transportation systems rely on real-time vehicle traffic information. However, in a two-lane traffic scenario, vehicles in adjacent lanes will interfere with vehicle detection in the target lane where the geomagnetic sensor is located. In order to solve this problem, it is necessary to design an innovative adjacent lane interference elimination algorithm to improve the accuracy and reliability of geomagnetic sensors in vehicle detection. In addition, obtaining vehicle type information can make the intelligent transportation system more fully understand the distribution and behavior of different types of vehicles on the lane, and provide strategic guidance for urban planning and resource allocation. In order to provide more scientific and more detailed data support for urban traffic management, it is urgent to accurately detect traffic flow and vehicle types. In this thesis, the related technologies are studied and analyzed, and the adjacent lane interference elimination and vehicle type recognition method based on geomagnetic sensor are proposed, and the accuracy of the method is verified by experiments. The main work of this thesis is as follows :

On the one hand, based on the design of state machine vehicle detection algorithm for normal traffic density, this thesis studies the problem of adjacent lane interference in two-lane traffic scene. In the scenario of deploying magnetic sensors on one side of a dual-carriageway, the presence of vehicles in adjacent lanes can affect the accuracy of vehicle detection algorithms, leading to difficulties in accurately obtaining traffic flow information for the target lane. To address this issue, a neighboring lane interference exclusion algorithm has been proposed for dual-carriageway traffic scenarios. Firstly, this thesis introduces and analyzes the equivalent magnetic dipole model of the vehicle from the vehicle structure, designs the multi-magnetic dipole extended target model, and determines the model parameters by differential evolution algorithm. Secondly, from the perspective of model simulation and theory, the first-order difference waveform of the magnetic field disturbance of the target

lane vehicle and the adjacent lane vehicle is analyzed, and the magnetic field characteristics for the adjacent lane interference elimination are extracted. Then, based on the extracted magnetic field features, a voting mechanism is designed to eliminate the adjacent interference in the two-lane traffic scene. Finally, the detection accuracy of the adjacent lane interference elimination algorithm in the two-lane traffic scene is verified by the actual data test. The experimental results show that the algorithm can effectively improve the accuracy of the target lane vehicle detection.

On the other hand, based on the accurate acquisition of the number of vehicles in the target lane, a vehicle type classification algorithm has been proposed for the vehicle type classification problem. First of all, the three-axis magnetic field data collected by the geomagnetic sensor is usually affected by the environmental magnetic field and the magnetic field disturbance caused by the vehicle. In order to extract the magnetic field disturbance caused by the vehicle, this thesis designs the geomagnetic environment baseline update method. By subtracting the collected original magnetic field data from the geomagnetic environment baseline, the magnetic field disturbance caused by the vehicle is obtained. Secondly, the magnetic field disturbance waveforms caused by different vehicle types are analyzed, the vehicle type recognition features are extracted, and the features are screened by the feature pairing elimination screening algorithm. Then, using the filtered feature set, this thesis designs a vehicle type recognition algorithm based on SoftMax regression. Finally, the accuracy of the vehicle type recognition algorithm is tested by the actual data. The experimental results show that the algorithm can identify the vehicle type with high accuracy.

Keywords: Geomagnetic Sensor, Magnetic Dipole Modeling, Adjacent Lane Interference, Vehicle Type Recognition

插图索引

图 2.1	车辆磁场扰动示意图.....	8
图 2.2	车辆经过时有车概率变化图.....	11
图 2.3	车辆检测状态机示意图.....	12
图 2.4	地磁车辆检测模块示意图.....	14
图 2.5	地磁车辆检测系统示意图.....	15
图 3.1	双车道场景车辆检测示意图.....	17
图 3.2	基于地磁传感器的邻道干扰排除方案.....	18
图 3.3	磁偶极子示意图.....	19
图 3.4	磁场感应变化图.....	20
图 3.5	扩展目标模型示意图.....	21
图 3.6	轿车及磁场波形图.....	24
图 3.7	厢式货车及磁场波形图.....	24
图 3.8	轿车的仿真与测量波形对比图.....	25
图 3.9	厢式货车的仿真与测量波形对比图.....	25
图 3.10	轿车和厢式货车 X 轴磁场差分变化图.....	29
图 3.11	轿车和厢式货车 Y 轴磁场差分变化图.....	29
图 3.12	轿车和厢式货车 Z 轴磁场差分变化图	29
图 3.13	实验测试场景图.....	34
图 3.14	目标车道和相邻车道实测数据平均能量的箱型图.....	35
图 4.1	车辆磁场分割示意图.....	41
图 4.2	车型分类特征说明图.....	42
图 4.3	冗余特征移除示意图.....	46
图 4.4	SoftMax 回归说明示意图.....	49
图 4.5	实验测试场景图.....	51
图 4.6	车型分类方案流程图.....	52
图 4.7	损失函数值变化图.....	53

表格索引

表 2.1	状态机参数设置.....	13
表 3.1	车辆参数值.....	23
表 3.2	参数集合中的参数含义及约束条件.....	25
表 3.3	车辆参数集合估计结果.....	25
表 3.4	标点三轴坐标值.....	30
表 3.5	邻道干扰排除算法参数设置.....	35
表 3.6	目标车道与相邻车道分类情况.....	35
表 4.1	车型分类标准.....	40
表 4.2	车型分类特征.....	41
表 4.3	车型分类特征袋外误差变化值.....	52
表 4.4	特征配对数量统计.....	53
表 4.5	车型分类准确率.....	54

符号对照表

符号	符号名称
$\mathbf{D}_k = \{\overline{D}_x(k), \overline{D}_y(k), \overline{D}_z(k)\}^T$	第 k 个时刻的磁场一阶差分
M_R	计算 Z 轴一阶差分极差所使用的时间窗的长度
$D^{M_R}(k)$	第 k 个时刻长度为 M_R 的时间窗内 z 轴一阶差分数据的集合
$R_z^{M_R}(k)$	第 k 个时刻 z 轴 M_R 个磁场一阶差分数据的极差
$e(k)$	k 时刻有无车辆经过的真实状态
$F_{l 0}(x)$	无车情况下特征的累积分布函数, $l \in \{x, y, z, R\}$
ρ_0	$e(k) = 0$ 条件下的联合概率与各特征单独的条件概率之间相关性的系数
C	有车概率的归一化常数
W_{arr}	车辆到达检测时间窗长度
W_{lea}	车辆离开检测时间窗长度
w_{arr}	检测车辆到达的窗长度计数变量
w_{lea}	检测车辆离开的窗长度计数变量
θ_{arr}	车辆到达检测概率阈值
θ_{lea}	车辆离开检测概率阈值
N_{arr}	车辆到达检测点数阈值
N_{lea}	车辆离开检测点数阈值
n_{arr}	检测车辆到达的采样点数计数变量
n_{lea}	检测车辆离开的采样点数计数变量
P_{car}	有车概率值
P_{env}	无车概率值
T_d	延时状态的延时点数
t_d	延时状态的采样点数计数变量
f_s	地磁传感器的采样频率
$\mathbf{B} = \{B_x, B_y, B_z\}^T$	磁场矢量
μ_0	真空中的磁导率
$\mathbf{r} = \{x, y, z\}^T$	磁偶极子到传感器之间的距离矢量
$\mathbf{m} = \{m_x, m_y, m_z\}^T$	磁偶极子的磁矩
d	磁偶极子的个数

$\mathbf{m}_i$	第 i 个磁偶极子的磁矩
$\Delta \mathbf{r}_i$	第 i 个磁偶极子距离目标中心 $\mathbf{r}$ 的相对距离矢量
R	磁偶极子到传感器之间的距离矢量 $\mathbf{r}$ 的模
$\mathbf{r}_0 = \{x_0, y_0, z_0\}^T$	磁偶极子到传感器之间的初始距离
$\mathbf{v} = \{v_x, v_y, v_z\}^T$	初始运动速度
t	运动时间
$\mathbf{F} = \{\mathbf{F}_x, \mathbf{F}_y, \mathbf{F}_z\}^T$	车辆的三轴测量磁场数据向量
Θ	多磁偶极子模型参数集合
$N_{\mathbf{F}}$	磁场序列长度
$\mathbf{F}(k) = \{F_x(k), F_y(k), F_z(k)\}^T$	第 k 个时刻采集的三轴测量值向量
$\mathbf{B}(k, \Theta)$	多磁偶极子模型在 k 时刻的三轴理论值向量
$\mathbf{Cov}$	测量误差的协方差矩阵
R_i	坐标轴 i 上数据的样本方差
$C(\Theta)$	损失函数
N_{Θ}	参数集合中的参数数量
$\hat{\Theta}$	估计参数集
$\mathbf{B}_k$	k 时刻的磁场矢量
R_k	. k .时刻磁偶极子到传感器之间距离矢量的模
P	波形的峰-峰值
$V_{\max}$	波形的最大峰值
$V_{\min}$	波形的最小谷值
σ	整段波形数据的标准差
n	波形的采样点数
x_i	整段波形的第 i 个数据
$\bar{x}$	整段波形数据的均值
E_{ave}	整段波形数据的平均能量
$\hat{y}$	投票机制的预测类别
$\mathbf{c}_k$	第 k 个基分类器的输出类别
w_j	第 j 个分类器的权重
p_{ij}	第 i 个样本被分类为类别 j 的概率
N	基分类器的数量
c_i	i 轴基分类器的输出
$E_{i,ave}$	i 轴的平均能量
T_i	i 轴的平均能量阈值

$\mathbf{F}_{env}(k)$	k 时刻的三轴环境基线
$R_i^L(k)$	k 时刻 i 轴磁场强度在时间窗 L 内的极差
L	计算极差和磁场均值差所使用的时间窗长度
$\mathbf{F}_i^L(k)$	从 k 时刻开始时间窗内的 L 个 i 轴原始磁场数据
$M_i^L(k)$	从 k 时刻开始长度为 L 的两个时间窗内磁场均值之差的绝对值
$\sigma_x, \sigma_y, \sigma_z$	环境磁场数据的三轴标准差
$R_{sum,k}$	三轴极差加权融合值
$M_{sum,k}$	三轴磁场均值差加权融合值
W_i	i 轴环境磁场数据极差的权重系数
RTH_R	三轴磁场极差加权融合值的阈值
RTH_M	三轴磁场均值差加权融合值的阈值
σ_{env}^2	三轴环境基线与三轴环境磁场数据的方差
$X_{max}, Y_{max}, Z_{max}$	三轴磁场最大值
X_R, Y_R, Z_R	三轴磁场极差
$X_{mean}, Y_{mean}, Z_{mean}$	三轴磁场均值
$X_{var}, Y_{var}, Z_{var}$	三轴磁场方差
$X_{n,max}, Y_{n,max}, Z_{n,max}$	三轴磁场峰值个数
$X_{n,min}, Y_{n,min}, Z_{n,min}$	三轴磁场谷值个数
$X_{p,max}, Y_{p,max}, Z_{p,max}$	三轴磁场最大值相对位置
$X_{p,min}, Y_{p,min}, Z_{p,min}$	三轴磁场最小值相对位置
Len	三轴磁场车辆磁场长度
X_{Pn}, Y_{Pn}, Z_{Pn}	三轴磁场正负能量比
Ev	三轴磁场平均能量
$X_{cross}, Y_{cross}, Z_{cross}$	三轴磁场过均值点个数
$X_{ApEn}, Y_{ApEn}, Z_{ApEn}$	三轴磁场近似熵
$V_n^{m,r}$	从第 j 个数据开始构建的新向量序列
$C_n^{m,r}$	向量 $V_j^{m,r}$ 与所有其他向量之间的欧氏距离
$A_n^{m,r}$	向量 $V_j^{m,r}$ 与其他向量 $V_k^{m,r}$ 距离小于等于 r 的概率
B	决策树的数量
E_b	第 b 个树在袋外样本上的误差
$E_{b,permuted}$	第 b 个树在对应于某个特征排列后的袋外样本上的误差
$\rho_{x,y}$	样本 x 和样本 y 之间的皮尔逊系数

R_t	皮尔逊相关系数阈值
Far	存储特征对的数组
c	车型分类的类别数量
$\mathbf{z} \in R^c$	未归一化的类别向量
g	特征的维度
$\mathbf{f} \in R^d$	输入特征向量
$\mathbf{b} \in R^c$	线性模型中的常数项
$.z_i.$	未归一化的类别向量中的第 i 个元素
$\mathbb{I}$	指示函数
y_i	第 i 组样本
$\hat{y}_{i,j}$	模型对样本 y_i 属于类别 j 的预测概率
$\mathbf{f}_i$	第 i 组样本 y_i 输入的特征集
$\boldsymbol{\varphi}$	常数向量
α	学习率
λ	权重衰减参数
θ	模型参数

缩略语对照表

缩略语	英文全称	中文对照
DE	Differential Evolution	差分进化算法
FPN	Feature Pairing Number	特征对编号
ITS	Intelligent Transportation System	智慧交通系统
KNN	K-Nearest Neighbors	K-最近邻
LASSO	Least Absolute Shrinkage and Selection Operator	最小绝对值收缩和选择算子
OOB PPT	Out-of-Bag Permuted Predictor Delta Error	袋外样本置换预测误差变化
RMSE	Root Mean Square Error	均方根误差
RMS	Root Mean Square	均方根值
SVM	Support Vector Machine	支持向量机

目录

摘要	I
ABSTRACT	III
插图索引	V
表格索引	VII
符号对照表	IX
缩略语对照表	XIII
第一章 绪论	1
1.1 研究背景及研究意义	1
1.2 国内外研究现状	2
1.2.1 邻道干扰排除方法国内外研究现状	2
1.2.2 车型分类方法国内外研究现状	3
1.3 研究内容及章节安排	5
1.3.1 研究内容	5
1.3.2 章节安排	6
第二章 地磁车辆检测原理及系统设计	7
2.1 引言	7
2.2 地磁车辆检测基本原理	7
2.2.1 车辆检测算法基本原理	7
2.2.2 基于一阶差分的状态机车辆检测算法	8
2.3 地磁车辆检测系统	14
2.3.1 地磁车辆检测模块	14
2.3.2 地磁车辆信息检测平台	15
2.4 本章小结	16
第三章 双车道交通场景下的邻道干扰排除算法研究	17
3.1 引言	17
3.2 双车道交通场景下的邻道干扰问题	17
3.3 双车道车辆磁场建模与分析	18
3.3.1 车辆磁场的磁偶极子模型	18
3.3.2 基于差分进化算法的参数估计	23
3.3.3 双车道车辆的一阶差分磁场波形仿真	26
3.4 双车道的邻道干扰排除算法	30

3.4.1	磁场特征及分类算法选择.....	30
3.4.2	分类算法设计.....	32
3.5	实验测试结果与性能分析.....	33
3.5.1	实验场景介绍.....	33
3.5.2	测试结果分析.....	34
3.6	本章小结.....	36
第四章	车型分类算法研究.....	37
4.1	引言.....	37
4.2	地磁环境基线更新方法.....	37
4.2.1	基线更新概述.....	37
4.2.2	磁场稳定性判断的特征提取.....	38
4.3	车型分类特征分析.....	40
4.3.1	车型分类特征提取.....	40
4.3.2	车型分类特征筛选.....	44
4.4	车型分类算法设计.....	47
4.4.1	车型分类算法选择.....	47
4.4.2	基于梯度下降算法确定参数值.....	48
4.5	实验测试结果与性能分析.....	51
4.5.1	实验场景介绍.....	51
4.5.2	测试结果分析.....	51
4.6	本章小结.....	55
第五章	总结与展望.....	57
参考文献		59
致谢		65
作者简介		67

第一章 绪论

1.1 研究背景及研究意义

在当前城市化迅速发展的背景下，交通拥堵和交通事故等问题直接影响着城市居民的生活质量和经济运行。为了有效解决这些问题，智慧交通系统（Intelligent Transportation System, ITS）成为了实现交通智能化管理的重要手段，并带领现代交通进入智能化和数字化时代^[1]。在此背景下，我国政府为促进智慧交通与智慧城市协同发展制定了多项国家政策。自上世纪 90 年代中期开始，我国相继组织进行了智能交通系统发展战略、标准体系、体系框架等方面的研究，集中进行了智能交通关键技术攻关和试点示范。2019 年，《交通强国建设纲要》中提出加大对智慧交通领域的支持和投入，以推动智慧交通技术、应用和产业的发展^[2]，这一举措标志着中国智慧交通进入了快速发展的阶段。2021 年，《关于科技创新驱动加快建设交通强国的意见》提出要加强新一代信息技术在交通领域的应用^[3]，来提升交通系统的智能化水平。这一系列举措旨在推动科技创新，促进交通领域的发展。

在智慧交通系统中，智慧公路的作用尤为突出，借助感知、通信和数据分析等技术，实现对道路交通的实时监控和智能化管理^[4]。交通信息的获取是实现交通流控制、交通安全管理和交通事故检测的必要基础^{[5][6]}。其中，车流量与车型信息作为交通信息的基本属性，快速而精准地获取这些交通信息，能够为智慧交通系统的交通大数据分析提供实时、可靠的数据源。

一方面，智慧公路系统中邻道干扰的存在极大地影响了系统监测的准确性。邻道干扰是指目标车道受到来自相邻车道磁场的干扰，会导致传感器误判、数据混淆等问题。根据实地调查，智慧公路系统中邻道干扰导致的误报率高达 30%，严重影响了系统对目标车道的有效监测。这一问题直接影响到交通管理决策的准确性，进而影响城市交通的运行效率和安全性^[7]。因此，如何有效地排除邻道干扰，提高系统准确性成为亟待解决的问题^[8]。

另一方面，车型分类作为智慧公路系统中的重要任务，直接关系到交通管理的智能化水平。通过精准识别车辆类型，可以实现对车流更精细的统计，为交通规划和管理提供更准确的数据支持^[9]。然而，由于车辆类型繁多、形态各异以及车流复杂多变等原因，车型分类在实际应用中仍存在一系列挑战^[10]。过去的研究表明，在当前交通系统中，对不同类型车辆的统计和识别存在较大误差，影响了交通规划和管理科学性和精准性^[11]。在实际的智慧公路系统中，邻道干扰导致误报率高的问题和车型分类存在的显著误差，迫切需要解决。

1.2 国内外研究现状

1.2.1 邻道干扰排除方法国内外研究现状

随着智慧交通系统的发展,地磁邻道干扰排除方法成为当前国际研究领域的热点之一。一些研究团队致力于提高地磁传感器的精度^{[12][13]},通过改进硬件结构和优化信号处理算法,以减小邻道信号对目标车道的干扰。Zhao 等人^[14]提出了一种非调制的三轴磁场补偿方法,该方法使用自旋交换弛豫自由原子磁力计,通过对零场谐振信号进行微分运算以获取关于磁场变化的信息。通过最大化一阶微分值,可以实现对磁场的补偿,即在泵浦和探测方向上同时抵消磁场的影响。实验结果表明,在探测、泵浦和垂直于泵浦-探测平面的方向上,补偿分辨率分别为 9 pT、7 pT 和 0.05 pT,从而提高了地磁信号的采集和分析精度。

同时,还有研究者利用地磁传感技术设计不同算法,以提高系统的抗干扰能力,更好地适应复杂交通环境。Liu 等人^[15]提出了一种使用三轴各向异性磁阻传感器进行车辆检测的方法。该方法集成了车辆混合算法和车辆运动状态判别算法,通过分析不同的地磁波形,解决车辆经过单一 AMR 传感器时产生的干扰。首先,通过综合分析 X、Y、Z 轴信息,使用双窗口算法提取单个车辆的波形。其次,车辆混合算法旨在同时区分车辆行驶状态并确定车流量。此外,车辆运动状态判别算法可识别车辆的运行状态,包括其在左车道、车道线或右车道的位置行驶。经过实验验证表明,车辆混合算法和车辆运动状态判别算法的平均准确率分别达到了 98.0%和 96.4%。Liu 等人^[16]的车辆检测器通过感应车辆周围的磁场变化以确定车辆状态。但是,车辆检测器的轴向、停车方向和磁场方向之间的三向关系会对检测灵敏度造成较大干扰。为了解决由近距离车辆干扰等三向角引起的低检测灵敏度问题,对三向角之间的基本关系进行了分析,并基于空间磁场原理建立了一种降低干扰的车辆检测模型。然后,通过将附近的车辆停放在不同的方向上,以检测两轴磁性车辆检测器的每个轴向。最后,确定如何使主轴输出高灵敏度峰值,副轴输出低灵敏度峰值,以提高检测灵敏度并减小相邻空间干扰。Taghvaceyan 等人^[17]提出了一种便携式路边磁感测器系统,用于进行车辆的数量统计、车型分类和行驶速度的测量。该磁感测器系统可以在不损坏道路的情况下,实现对目标车道交通流量的监测。为了使系统对大型车辆在相邻车道上行驶所产生的误差具有鲁棒性,提出了一种基于磁场模型的算法。如果不进行纠正,这些误差会导致 8%的错误检测,而磁场模型算法的使用能够将错误检测降低到 1%。

同时,一些研究者还关注车辆行驶过程中地磁信号的时空变化规律,通过构建复杂的地磁信号模型^{[18][19]},以提高对邻道干扰的识别和排除能力。这种基于模型的方法有望在复杂交通场景下展现出更好的性能。虽然国内外在地磁邻道干扰排除方法方面取得了一些积极的成果,但仍然面临一系列挑战,包括在复杂交通场景下的准确性要

求、系统实时性的需求以及多传感器融合的技术难题等。未来的研究方向应集中在提高算法的实时性和鲁棒性，以适应不同交通环境的需求，并推动地磁邻道干扰排除方法在实际应用中取得更进一步的发展。本文通过分析地磁信号的时空变化规律，并结合构建的地磁信号模型，提出了实时性较高的双车道交通场景下的邻道干扰排除算法。

1.2.2 车型分类方法国内外研究现状

随着城市化和交通流量的不断增长，能够实时、准确地了解道路上行驶车辆的种类和数量变得愈加重要。车型信息作为车辆信息的基本属性，对其快速、精准的统计能够为智慧交通系统进行交通大数据分析提供实时、可靠的数据源^{[20][21]}。车型分类技术包括计算机视觉和深度学习等先进技术，旨在自动识别道路上的各种车型，如轿车、卡车、摩托车等。该技术不仅有助于改善交通流量监测和管理，还在智慧交通、道路安全和城市规划等领域发挥着关键作用。

车型分类涉及多种传感器，常见的有相机、雷达等。每种传感器都具有各自的优点和适用的场景。Hussain 等人^[10]提出使用图像空间分辨率和颜色进行车型分类。这是一种基于视觉的分类技术，仅依赖于数字摄像机而无需额外的硬件组件。尺寸和颜色是影响图像采集的两个重要特征，基于这两个特征，作者对数据集应用了一系列图像分类器，将每个数据集缩小到不同比例，以生成各种空间分辨率。实验发现，对于使用图像分类方法进行车型分类的情况，即使改变了车辆图像的颜色和空间分辨率，最终的分类结果也不会有显著变化。但是，这种方法所需的处理时间和空间分辨率之间存在某种程度的相关性，增加图像的空间分辨率会导致处理时间增加。Liu 等人^[22]提出采用分布式光纤声学传感器进行车辆类型检测，并详细介绍了信号处理、特征提取等综合分类方法。该传感设备基于瑞利散射光，用于实时车辆检测、分类和速度估计。通过分布式光纤声学传感器技术，利用光纤作为传感器，对其上任意点的声学信号进行监测，实现对整个光纤链路上声学事件的监测和定位。该技术使用分布式传感器形式的感知光纤来收集交通振动信号，然后从信号中提取多个特征，用于估计车辆数量和识别车辆类型。根据车辆振动信号的特征，改进了小波去噪算法和双阈值算法。改进后的算法用于重构信号、提取特征并获得车辆数量和速度。在完成所有特征提取后，通过支持向量机分类器实现车辆类型检测。实验检测结果表明车辆检测精度超过 80%，速度估计误差小于 5%，车辆分类准确率超过 70%。Theagarajan 等人^[23]提出了一种基于车辆后视视频的深度学习方法，利用物理和视觉特征对车型进行分类，包括轿车、小型货车、SUV 和皮卡四个类别。根据高速公路上的相机几何设置，对车辆进行物理测量，包括视觉后部离地高度、车牌和后保险杠之间的距离以及车辆高度等物理特征。视觉特征，也称为基于外观的特征，是使用卷积神经网络从输入图像中提取的。本方法中使用物理特征实现了 93.22% 的分类准确性，使用视觉特征实现了 91.52%

的分类准确性。此外，将这两种特征融合在一起，实现了更高的 94.81% 的分类准确性。

车型分类方法的研究主要集中在提高识别准确性和推动多传感器融合技术的应用。研究者利用传感器获取的数据，通过引入先进的深度学习模型和机器学习算法，实现对不同车辆类型的准确辨识。Odat 等人^[24]提出一种机器学习方法，利用红外线感测器和超声波测距器的组合进行车型分类。该方法的框架依赖于动态贝叶斯网络，以在空间和时间上融合异构数据进行车辆检测。为了估计即将进入的车辆速度，首先使用交叉相关和小波变换方法来估计不同传感器信号之间的时间延迟。然后，引入了一个基于贝叶斯网络的校准和自校正模型，通过所有传感器对检测到的车辆的速度和长度进行联合推断。此外，使用超声波和被动红外传感器的测量来进行车辆分类。使用实验性的双红外和超声波交通传感器验证数据，结果表明车辆检测准确率达到 99%，车辆速度估计平均误差为 5 kph，车辆长度估计平均误差为 0.7 米，车型分类方面准确性很高。Shvai 等人^[25]提出了一种综合使用两种技术的车型分类方法，首先基于梯度上升的分类器用于预处理数据和初步分类，进一步使用卷积神经网络提高车型分类的准确性和效率。该方法在 VINCI Autoroutes 法国网络的收费站收集的实际数据集上进行评估，结果表明其性能明显优于现有的自动收费系统，从而极大减轻了人工操作员的工作负担。

地磁传感器具有低成本、小巧易安装的优势^[26]，与依赖光学信息的传感器不同，它在低光、恶劣天气或夜间都能表现良好，且不依赖视觉信息。地磁传感器无需捕捉图像，降低了对隐私的侵犯，其低功耗工作方式适用于需要长时间运行、无需频繁更换电池的应用场景^[27]。在特定场景，如停车场和道路上的车辆检测，地磁传感器表现出色，能够精确地检测车辆的存在和移动。一些团队通过深入研究车辆在地磁场中的独特特征，提出了一系列识别方法。Balid 等人^[28]提出了一种基于无线磁强计传感器实现车辆计数和分类的系统。无线磁强计传感器可以感知车辆产生的磁场变化，从而实现对车辆的计数和分类。这种系统可以用于监测交通流量、分析交通状况，以及为交通管理提供数据支持。调查显示，该系统在高速公路和城市道路条件下，在自由流动和拥堵交通条件下，性能都是一致而准确的。道路检测、路侧检测、速度估计和基于长度的车型分类的准确率分别为 99.65%、99.95%、97.42% 和 97.65%。Wang 等人^[29]提出了一种名为 SenseMag 的低成本方法，用于车型分类，支持交通管理部门进行交通监测工作，帮助其更好地管理和运营交通系统。该方法可以快速地获得关键道路和高速公路的整体车流量情况。相较于安装和维护车载 GPS 传感器或摄像头网络所需的费用，SenseMag 方法的实施成本较低，另外 SenseMag 方法不需要收集与驾驶员个人身份或行为相关的信息，因此不会侵犯驾驶员的隐私权。SenseMag 方法将一对非侵入式磁传感器部署在笔直的道路段上，用于车型分类。该方法在每个传感器节点

接收到的磁信号中准确的时间点上进行噪声过滤和分段，这些时间点对应着车辆到达或离开每个传感器节点的时刻。此外，SenseMag 方法通过分层识别模型和时间频谱特征的应用，以及半自动学习技术的使用，可以实现对车辆类型的有效识别和分类。实地实验结果表明 SenseMag 方法在车型分类和车辆长度分类方面具有很高的性能和准确性，可以有效地应用于交通监测和管理等领域。

无论国内还是国外，地磁车型分类方法仍然面临一些共同的挑战。首先，提高复杂交通环境下的检测准确性是一个关键问题。不同车型在不同路况下的地磁响应存在较大差异，因此需要更精细的识别模型。其次，高速运动的车流对算法的运算效率和实时性提出了更高的要求。此外，需要深入研究不同传感器的应用，以实现更全面、鲁棒的车型分类^[30]。综上所述，国内外在地磁车型分类方法的研究中都取得了一些进展，但仍需进一步攻克技术难题，以满足日益复杂的交通环境对车辆识别精度和实时性的需求，推动地磁车型分类方法更好地服务于智慧交通系统的发展。本文在能够准确检测目标车道车流量的条件下，从地磁环境基线出发，提取车辆引起的磁场扰动，通过分析不同车辆类型引起的磁场扰动，提出了运算效率和实时性较高的车型分类方法。

1.3 研究内容及章节安排

1.3.1 研究内容

本文深刻认识到智慧交通系统在实际应用中所面临的挑战，同时考虑到提高交通管理效率的紧迫需求和传感器技术的不断进步。地磁传感器可以感知车辆通过地面时产生的磁场变化，通过检测这些磁场变化，可以确定车辆的位置和移动方向，记录车辆的数量，并根据车辆的特征识别车辆的类型。因此，本文使用地磁传感器来监测道路上车辆目标的移动。

本文首先介绍了地磁车辆检测模块的基本原理，以及在现有技术基础上构建的车辆信息检测平台各系统组成部分的功能。随后，对双车道场景下的邻道干扰问题进行分析，在对双车道车辆磁场进行建模与分析的基础上，提出了适用于双车道的单地磁邻道干扰排除算法。该算法通过对比目标车道与相邻车道的车辆磁场波形来提取磁场特征，并设计算法区分目标车道车辆与邻道干扰。进一步对检测到的目标车道车辆进行车型分类。首先，提取多个用于车型分类的磁信号特征，并通过决策树的重要性评估以及皮尔逊相关系数剔除冗余特征，通过特征配对消除的筛选算法，筛选出准确率和效率最高的新特征集。基于新特征集，使用 SoftMax 分类器实现基于单地磁传感器的车型分类。

1.3.2 章节安排

本文的各章节安排如下：

第一章首先介绍了邻道干扰问题和车型分类的研究背景和意义，探讨了国内外采用地磁传感器进行车辆检测的研究现状和发展趋势，最后概述了本文的主要研究内容和章节安排。

第二章介绍了地磁车辆检测原理及系统设计。本章节首先介绍了使用地磁传感器进行车辆检测的基本原理，并通过分析地磁信号特征，提出了基于一阶差分信号的状态机车辆检测算法。另外，为实现对车辆数据的全面感知，确保交通状况的准确监测和实时响应，本章节简要介绍了使用的地磁车辆检测系统，主要包括地磁车辆检测模块和地磁车辆信息检测平台。

第三章介绍了双车道交通场景下的邻道干扰排除算法。本章节在第二章描述的一阶差分车辆检测算法的基础上，重点讨论了双车道交通场景中的邻道干扰问题。具体而言，分析了车辆的磁偶极子模型，提出了多磁偶极子扩展目标模型，使用差分进化算法对模型参数进行求解，并通过仿真模型对邻道干扰问题进行了分析。在仿真分析的基础上，对提出的单个地磁传感器在双车道交通场景下排除邻道干扰的算法进行了实地测试，验证了所设计算法的准确性。

第四章介绍了车型分类算法。本章节在第二章和第三章所述一阶差分车辆检测算法和邻道干扰排除算法的基础上，在能够准确检测目标车道车流量的条件下，从地磁环境基线出发，提取车辆引起的磁场扰动。通过分析不同车辆类型引起的磁场扰动，提取了用于车型分类的特征集，并对特征进行筛选，根据特征配对消除的筛选算法得到的新特征集设计了基于 SoftMax 回归的车型分类算法。最后，本章通过实地测试验证了车型分类算法的精度。

第五章为总结与展望部分。本章节会对论文的主要研究内容进行总结，并对未来可能的研究方向和工作进行展望。

第二章 地磁车辆检测原理及系统设计

2.1 引言

智慧交通系统通过应用先进的技术和方法来改善交通系统的运行和管理，旨在减少交通拥堵、提高交通安全性并提供实时交通信息^[31]。因此，智慧交通系统被广泛研究和应用，能够有效提高城市居民的出行体验，减少交通事故，同时也提升了城市的整体形象和生活质量。近年来，地磁传感器引起了研究人员的广泛关注。与其他传感器相比，地磁传感器具有价格低廉、不受天气影响等优点。由于这些优势，地磁传感器可以被广泛部署在道路旁，为智慧交通系统提供车辆信息，从而提高交通运输的效率和安全性，为改善城市交通状况和提高城市生活质量做出贡献。

本章节首先介绍了使用地磁传感器进行车辆检测的基本原理，并通过分析地磁信号特征提出基于一阶差分的状态机车辆检测算法。车辆检测系统是完成车流检测的关键，此外，为了实现智慧公路系统中感知数据与云平台的实时交互，本章节将简要介绍所使用的地磁车辆检测模块、通信基站和信息检测平台，并建立一个能够实时感知和监测车辆行驶情况，并与其他设备进行通信和协作的车辆检测系统。

2.2 地磁车辆检测基本原理

2.2.1 车辆检测算法基本原理

地球的磁场在不同地点具有不同的大小和方向，赤道最弱，两极最强。地磁场可以分为稳定磁场和变化磁场两部分，其中稳定磁场只会在环境因素变化下缓慢改变，是地磁场的主要组成部分。几乎所有地磁应用都是基于地球稳定磁场开发的，其强度通常在 $0.5 \sim 0.6 \text{ gauss}$ 之间。虽然地球磁场在短时间内是稳定的，但长期应用需要考虑其缓慢变化的动态性。

车辆通常由铁磁性材料构成，这些材料对磁场具有较高的感应能力。因此，当车辆行驶时，它会对地磁场产生一定程度的扰动，导致周围地磁场发生变化。磁阻传感器利用各向异性磁阻材料制造敏感元件，其电阻随外部磁场变化而变化。地磁传感器通常埋在地下，当车辆经过时，车辆金属部分会改变地磁场分布，影响传感器中的磁场敏感性，从而引起电阻变化，这使得地磁传感器能够检测到车辆的存在、移动和停留。如图 2.1 所示为车辆磁场扰动示意图，在理想情况下，磁感线应当是均匀分布的，但当车辆经过时，不同位置的磁感线由于受到的扰动程度不同，会出现不同程度的形变。




图 2.1 车辆磁场扰动示意图

通过地磁传感器感知磁场变化作为一种车辆检测技术,其基本原理涉及地球磁场的感应、磁感应效应和传感器响应等复杂过程。首先,地球磁场是地球内部电流产生的复杂磁场,这一磁场在地球表面具有空间变化和方向差异^[32]。地磁传感器通过感应地球磁场的微小变化,利用车辆金属结构对磁场的影响进行探测,这是地磁传感器实现车辆检测的基础。当车辆驶过地磁传感器的检测区域时,车身金属部分会扰动周围地球磁场,导致磁场产生畸变,这一磁场的变化会引起地磁传感器内部线圈感应到感应电动势。根据法拉第电磁感应定律,感应电动势与磁场的变化率成正比。因此,随着车辆移动,地磁传感器产生的电信号发生变化,形成与车辆运动特征相关的电信号。这个感应的电信号是模拟信号,需要经过模数转换器处理,将其转换为数字信号。随后,数字信号进入信号处理阶段。在这个阶段,信号经过滤波、放大和去噪等处理,以提高信号的稳定性和可靠性。这些处理步骤有助于减少来自环境和设备的干扰,确保地磁传感器能够准确地捕捉到车辆引起的磁场变化。最终,经过处理的信号被送入系统的数据分析单元。该单元应用先进的算法和模型来识别和分析车辆的数量、速度、方向、类型等特征^[29]。分析结果不仅实现了对交通流量的实时监测,还为城市交通管理、停车场资源的优化和智慧交通系统的发展提供了有力的支持。

总的来说,地磁传感器通过感应地球磁场的微小变化,实现对车辆的高效检测。利用磁感应效应将感知到的磁场变化转化为电信号,经过处理和分析,最终为城市交通管理和停车场系统提供了丰富的实时数据,为提升交通效率和优化城市交通系统做出了积极贡献。

2.2.2 基于一阶差分的状态机车辆检测算法

当车辆行驶过传感器附近时,会对周围的地磁场产生一定程度的扰动,导致传感器接收到的磁场数据发生变化。而在车辆离开地磁传感器后,车辆产生的磁场扰动会

随着车辆的远离而减弱，磁场数据会迅速回归到稳定状态^[33]。基于这种磁场扰动的检测，地磁传感器可以实现对车辆经过的识别。由于不同车辆经过时在三轴上产生的磁场变化并不相同，不能仅依靠某个坐标轴的一阶差分信号进行车辆检测，而应当设计一种融合三轴数据的检测方法。可以理解为，当三轴磁场整体呈现出较大的波动时，才认为有车辆经过。

首先需要明确车辆检测所使用的数据特征。经过对 RM3100 传感器各轴数据的分析与验证，选择使用 X 轴磁场一阶差分值、Y 轴磁场一阶差分值以及 Z 轴磁场一阶差分值共三个特征进行车辆检测。分别用 $\bar{D}_x(k)$ 、 $\bar{D}_y(k)$ 和 $\bar{D}_z(k)$ 表示使用有限长脉冲响应数字滤波器滤波后的 X、Y、Z 三轴磁场一阶差分数据。本文以 X 轴磁场一阶差分信号为例，给出基于单个特征的有车概率计算方法。通过 $\bar{D}_x(k)$ 得到有车概率的计算式如式(2-1)和式(2-2)所示。

$$P(e(k)=1|\bar{D}_x(k))=1-P(e(k)=0|\bar{D}_x(k)) \quad (2-1)$$

$$P(e(k)=0|\bar{D}_x(k))=1-F_{x|0}(x)+F_{x|0}(-x)|_{x=\bar{D}_x(k)} \quad (2-2)$$

其中， $e(k)$ 表示 k 时刻的真实状态， $e(k)=0$ 表示无车经过， $e(k)=1$ 表示有车经过。 $P(e(k)=1|\bar{D}_x(k))$ 表示已知 X 轴一阶差分值 $\bar{D}_x(k)$ 的条件下， $e(k)=1$ 的概率； $P(e(k)=0|\bar{D}_x(k))$ 表示已知 X 轴一阶差分值 $\bar{D}_x(k)$ 的条件下， $e(k)=0$ 的概率。在实际场景中，地磁传感器采集到的一阶差分信号是完全随机的，即可以将 k 时刻采集到的 $\bar{D}_x(k)$ 视为一个随机变量，其取值应当服从一定的概率分布。因此，令 $F_{x|0}(x)$ 表示在 $e(k)=0$ 的条件下 $\bar{D}_x(k)$ 所服从概率分布的累积分布函数。本文通过对原始磁场数据进行统计的方法确定了分布 $F_{l|0}(x)$ ， $l \in \{x, y, z\}$ 。

基于三轴磁场数据特征进行车辆检测的问题可以理解为：在 k 时刻，已知各数据特征的估计概率 $P(e(k)=1|\bar{D}_l(k))$ ， $l \in \{x, y, z\}$ 的基础上，从概率角度出发，将上述问题转化为对 $P(e(k)=0|\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))$ 和 $P(e(k)=1|\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))$ 这两个概率的计算。为方便表述，将两个概率分别称为无车概率和有车概率，并用 P_{env} 表示无车概率，用 P_{car} 表示有车概率。显然，无车概率和有车概率之和为 1。这里以无车概率 P_{env} 为例，讨论其计算方法，有车概率的计算式如式(2-3)所示。

$$P_{car}=1-P_{env} \quad (2-3)$$

根据贝叶斯公式，对 $P(e(k)=0|\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))$ 进行转换，得到无车概率计

算式如式(2-4)所示。

$$P_{env} = \frac{P(\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k) | e(k) = 0)P(e(k) = 0)}{P(\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))} \quad (2-4)$$

基于式(2-4)计算 P_{env} 比较困难，因为计算分子的后验概率会涉及三个特征判断结果的联合概率分布，而该分布很难获取。因此，需要结合估计结果之间的条件独立性对式(2-4)进行展开。实际情况中，较难分析 $\bar{D}_l(k)$ 之间的独立性，因此引入系数 ρ_0 ，得到的关系式如式(2-5)所示。

$$P(\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k) | e(k) = 0) = \rho_0 \prod_{l=x,y,z} P(\bar{D}_l(k) | e(k) = 0) \quad (2-5)$$

通过对无车时的各特征数据进行统计，能够得到 ρ_0 的估计值。将式(2-5)代入式(2-4)得到的计算式如式(2-6)所示。

$$P_{env} = \frac{\rho_0 P(e(k) = 0) \prod_{l=x,y,z} P(\bar{D}_l(k) | e(k) = 0)}{P(\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))} \quad (2-6)$$

这里以式(2-5)中的 $P(\bar{D}_x(k) | e(k) = 0)$ 为例，再次使用贝叶斯式，得到的计算式如式(2-7)所示。

$$P(\bar{D}_x(k) | e(k) = 0) = \frac{P(e(k) = 0 | \bar{D}_x(k))P(\bar{D}_x(k))}{P(e(k) = 0)} \quad (2-7)$$

类似地，可以得到 $P(\bar{D}_y(k) | e(k) = 0)$ 和 $P(\bar{D}_z(k) | e(k) = 0)$ 的贝叶斯式展开，将这些展开式代入式(2-6)并整理得到的计算式如式(2-8)和式(2-9)所示。

$$P_{env} = \frac{P(\bar{D}_x(k))P(\bar{D}_y(k))P(\bar{D}_z(k))}{P(\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))} \cdot \frac{\rho_0 \prod_{l=x,y,z} P(e(k) = 0 | \bar{D}_l(k))}{P(e(k) = 0)^2} \quad (2-8)$$

$$C = \frac{P(\bar{D}_x(k))P(\bar{D}_y(k))P(\bar{D}_z(k))}{P(\bar{D}_x(k), \bar{D}_y(k), \bar{D}_z(k))} \quad (2-9)$$

其中， C 是一个归一化常数，其值应当使得无车概率和有车概率之和为 1，所以将式(2-9)代入式(2-8)得到的三轴各数据特征的融合式如式(2-10)所示。

$$P_{env} = C \cdot \frac{\rho_0 \prod_{l=x,y,z} P(e(k)=0|\bar{D}_l(k))}{P(e(k)=0)^2} \quad (2-10)$$

在 k 时刻，基于各特征值使用式(2-1)和式(2-2)得到基于单个特征的车辆概率，再利用式(2-3)和式(2-10)得到特征融合后的有车概率 P_{car} 和无车概率 P_{env} 。根据得到的 P_{car} 设计车辆检测算法。

本文给出如下车辆检测算法：设置一个到达检测时间窗和一个离开检测时间窗，窗长度分别为 W_{arr} 和 W_{lea} 。另外，设置用于到达检测和离开检测的概率阈值 θ_{arr} 和 θ_{lea} 以及点数阈值 N_{arr} 和 N_{lea} 。其中， $\theta_{arr} \in (0,1)$ ， $\theta_{lea} \in (0,1)$ 。当检测到连续 W_{arr} 个时刻中有 N_{arr} 个时刻计算出的 P_{car} 大于 θ_{arr} 时，则认为车辆到达；类似地，当检测到连续 W_{lea} 个时刻中有 N_{lea} 个时刻计算出的 P_{car} 小于 θ_{lea} 时，则认为车辆离开。图 2.2 是一辆车辆经过地磁传感器时计算得到的三轴磁场一阶差分及其相应的有车概率变化情况。可以看出有车经过时有车概率基本稳定在 1 附近，无车经过时有车概率在 0 附近波动。为了保证一定的容错性，避免阈值取值过于极端导致的车辆误检测，本文在进行车辆检测时将 θ_{arr} 取值为 0.9， θ_{lea} 取值为 0.3。




图 2.2 车辆经过时有车概率变化图

对于 W_{arr} 、 N_{arr} 、 W_{lea} 和 N_{lea} 的取值, 首先分析了各轴无车经过时一阶差分信号的自相关函数, 然后基于无车经过数据的波动特征再确定各参数的取值。根据分析, 各轴自相关函数基本趋势一致, 相关系数在 11 个采样点后基本为 0, 在 6 个采样点附近为负值。这意味着对于无车经过的一阶差分信号而言, 当前时刻的数据至多会对其后的连续 10 个数据产生影响。进一步可以认为, 当一阶差分信号在某个时刻因环境因素产生异常波动时, 该异常波动会在连续 10 个点之后平复。因此, W_{arr} 和 W_{lea} 的取值应当比 11 稍大一些, 否则可能将无车经过时数据的异常波动误检测为车辆到达。综上所述, 本文将 W_{arr} 和 W_{lea} 取值为 15。

关于 N_{arr} 和 N_{lea} 的确定, 需要统计多辆单独经过地磁传感器的车辆数据, 计算对应的 P_{car} , 统计车辆内部数据每 W_{arr} 个连续时刻中满足 $P_{car} > \theta_{arr}$ 的数据个数, 以及每 W_{lea} 个连续时刻中满足 $P_{car} < \theta_{arr}$ 的数据个数。经统计, 本文取 N_{arr} 为 11, 取 N_{lea} 为 6。即只有当连续 W_{arr} 个时刻有 11 个时刻的 P_{car} 大于 θ_{arr} 时, 认为当前磁场波动不是由环境引起的, 而是由车辆到达引起的; 只有当连续 W_{lea} 个时刻有 6 个时刻的 P_{car} 小于 θ_{arr} 时, 认为当前磁场稳定不是由车辆内部引起的, 而是由车辆离开引起的。




图 2.3 车辆检测状态机示意图

基于上述检测车辆到达与离开的方法, 图 2.3 给出了基于一阶差分的状态机车辆检测算法。每个时刻, 状态机会根据当前时刻计算出的 P_{car} 进行状态跳转。所示状态

机一共分为五个状态：无车状态 S1、到达检测状态 S2、延时状态 S3、车辆经过状态 S4 和离开检测状态 S5。通常情况下，为了避免出现将一辆车检测为多辆车的问题，在检测车辆到达后不应立即进行车辆离开检测。因此，通过分析车辆经过地磁传感器所需的最小点数设置了延时状态 S3。令 T_d 表示 S3 状态的延时点数，其取值可根据车辆经过信标时能够产生的最小数据点数进行限定。

通过对实测车流数据的统计分析，本文确定了状态机中涉及各个参数的设置，如表 2.1 所示。

表 2.1 状态机参数设置

参数	参数名称	参数设置
θ_{arr}	车辆到达检测概率阈值	0.9
θ_{lea}	车辆离开检测概率阈值	0.3
N_{arr}	车辆到达检测点数阈值	11
N_{lea}	车辆离开检测点数阈值	6
W_{arr}	车辆到达检测时间窗长度	15
W_{lea}	车辆离开检测时间窗长度	15
T_d	延时状态的延时点数	7

各个状态转换关系的文字说明如下所示。

无车状态 S1：无车经过时，状态机均处于该状态下，且信标初始化后也将首先进入该状态。在 S1 状态内，将不断进行 P_{car} 与 θ_{arr} 大小关系的比较。若 $P_{car} \geq \theta_{arr}$ ，表示此时可能有车辆到达，则状态机跳转到 S2 状态；否则，继续停留在 S1 状态。

到达检测状态 S2：从 S1 状态跳转至 S2 状态时，会设置一个满足 $P_{car} \geq \theta_{arr}$ 条件的计数变量 n_{arr} 和一个窗长度计数变量 w_{arr} 并初始化为 1。之后，在 S2 状态内会先判断 w_{arr} 和 W_{arr} 的大小关系，当 $w_{arr} < W_{arr}$ ，令 $w_{arr} = w_{arr} + 1$ ，此时若 $P_{car} \geq \theta_{arr}$ ，令 $n_{arr} = n_{arr} + 1$ ；当 $w_{arr} = W_{arr}$ ，此时若滑动窗内第一个点满足 $P_{first} \geq \theta_{arr}$ ，令 $n_{arr} = n_{arr} - 1$ ，将长度为 W_{arr} 的窗口向右滑动一个点，此时若滑动窗内最后一个点满足 $P_{last} \geq \theta_{arr}$ ，令 $n_{arr} = n_{arr} + 1$ 。当 $n_{arr} = 0$ 时，跳转到 S1 状态；当 $0 < n_{arr} < N_{arr}$ 时，继续停留在 S2 状态；当 $n_{arr} \geq N_{arr}$ 时，跳转到 S3 状态。

延时状态 S3：从 S2 状态跳转至 S3 状态时，会设置一个计数变量 t_d 并初始化为 0，该状态下将进行 T_d 个采样时刻的延时。所以，当 $0 \leq t_d < T_d$ 时，令 $t_d = t_d + 1$ ，并继续停留在 S3 状态；否则，跳转到 S4 状态。

车辆经过状态 S4：在 S4 状态内，将不断进行 P_{car} 与 θ_{lea} 大小关系的比较，若

$P_{car} < \theta_{lea}$ ，表示此时车辆可能要离开，则状态机跳转到 S5 状态；否则，继续停留在 S4 状态。

离开检测状态 S5: 在 S5 状态中进行车辆是否离开的判断，思路与 S2 状态类似。从 S4 状态跳转至 S5 状态时，设置一个满足 $P_{car} < \theta_{lea}$ 条件的计数变量 n_{lea} 和一个窗长度计数变量 w_{lea} 并初始化为 1。之后，在 S5 状态内会先判断 w_{lea} 和 W_{lea} 的大小关系，当 $w_{lea} < W_{lea}$ ，令 $w_{lea} = w_{lea} + 1$ ，此时若 $P_{car} < \theta_{lea}$ ，令 $n_{lea} = n_{lea} + 1$ ；当 $w_{lea} = W_{lea}$ ，此时若滑动窗内第一个点满足 $P_{first} < \theta_{lea}$ ，令 $n_{lea} = n_{lea} - 1$ ，将长度为 W_{lea} 的窗口向右滑动一个点，此时若滑动窗内最后一个点满足 $P_{last} < \theta_{lea}$ ，令 $n_{lea} = n_{lea} + 1$ 。当 $n_{lea} = 0$ 时，跳转到 S4 状态；当 $0 < n_{lea} < N_{lea}$ 时，继续停留在 S5 状态；当 $n_{lea} \geq N_{lea}$ 时，跳转到 S1 状态。

2.3 地磁车辆检测系统

2.3.1 地磁车辆检测模块

本文采用的地磁车辆检测模块主要由地磁传感器、微处理器、电源模块、LED 指示灯、LoRa 无线通信模块组成，其实物图如图 2.4 所示。地磁车辆检测模块使用的地磁传感器为 PNI RM3100，本文的检测算法所使用的采样频率为 100Hz。PNI RM3100 中有两个 Sen-XY-f (pn13104) 传感器、一个 Sen-Z-f (pn13101) 传感器和一个 MagI2C (13156) 控制芯片，能够实现三维空间中磁场大小的测量。




图 2.4 地磁车辆检测模块示意图

地磁场在三维空间中是一个有方向的矢量，该矢量 $\mathbf{B}$ 的表达式如式(2-11)所示。

$$\mathbf{B} = \{B_x, B_y, B_z\}^T \quad (2-11)$$

其中, B_x, B_y, B_z 分别表示传感器在 X、Y、Z 三个正交轴上的磁场矢量, 传感器的 X 轴与车辆行驶方向互相平行, Y 轴垂直于 X 轴并且与车道平面平行, Z 轴则垂直于车道平面指向上方。

微处理器采用的是 STM32F103RCT6 单片机, 其处理速度为 72MHz, 能够完成对车辆信息的滤波融合, 以及磁场特征处理。电源模块通过太阳能电池板给负载电池充电, 再由负载电池为整个传感器节点供电。LED 指示灯在检测到车辆经过或发生异常停车时将亮起。LoRa 通信模块使用的是 SX1278 LoRa 扩频无线模块, 能够降低电流消耗并实现长距离扩频通信。

2.3.2 地磁车辆信息检测平台

为了实现智慧公路系统中感知数据与云平台的实时交互, 搭建了地磁车辆检测系统如图 2.5 所示, 检测系统的实际工作界面如图 2.5 中的云平台部分所示。




图 2.5 地磁车辆检测系统示意图

地磁车辆检测系统由地磁车辆检测模块、通信基站与云平台构成。地磁车辆检测模块沿车道线等间隔部署, 相邻检测节点之间间隔 8~15 米。当车辆检测模块检测到车辆经过时, 会将车辆相关的信息保存在传感器内部, 并由 LoRa 无线通信模块上传至路段附近的通信基站, 再通过无线网络将其转发给云平台。云平台具有强大的计算和存储能力, 能够对接收到的车辆信息进行更深入的分析 and 处理。通信基站作为数据传输的媒介, 内部有 Linux 操作系统, 采用全双工物联网网关, 网关可以通过 4G 网

络连接到云平台服务器，实现稳定且长距离的数据传输。云平台采用微服务架构，用于整合通信基站发送的车辆信息，可根据需要灵活实现分布式部署，让交通流数据可视化呈现，助力交通管理向数字化、精确化、智能化方向转变。

2.4 本章小结

本章首先介绍了车辆通过地磁传感器时的磁场检测原理，提出了一阶差分的状态机车辆检测算法，为后续章节对单一车辆磁场的分析提供了先决条件。其次，本章介绍了地磁车辆检测系统的基本组成，主要包括地磁车辆检测模块、通信基站和云平台，为后续描述的算法提供了硬件基础和信息平台。

第三章 双车道交通场景下的邻道干扰排除算法研究

3.1 引言

在利用地磁传感器进行车辆检测的过程中排除邻道磁场干扰专注于仅检测目标车道车辆具有重要的实际意义。这种精确性检测具有多方面优势：首先，它能够提供更准确的目标车道交通流量信息，为交通管理系统和道路规划提供可靠的基础数据；另外，降低误检率有助于提高数据的可信度，这对于城市交通管理决策至关重要；同时，准确地检测目标车道上的车辆能够更及时地识别和应对交通事件，从而提高整体交通安全性；最后，准确的交通流量信息有助于优化交通流，减少拥堵，提升整体驾驶体验。总的来说，排除邻道干扰的方法使得地磁传感器能够更好地为城市交通管理和规划提供更精细化、可靠的数据支持。

本章节在第二章描述的一阶差分车辆检测算法的基础上，从双车道交通场景下的邻道干扰问题出发，介绍并分析了车辆的磁偶极子模型。建立了多磁偶极子扩展目标模型，并通过差分进化算法对参数进行求解，从而实现对双车道车辆一阶差分磁场波形的仿真分析。在仿真分析的基础上，进行实地测试，并提出了单个地磁传感器在双车道交通场景下的邻道干扰排除算法。最后，本章使用提出的方法在道路上进行了实地测试，验证了所设计算法的精度和稳定性。

3.2 双车道交通场景下的邻道干扰问题

本节重点研究了在双车道场景中如何使用地磁传感器准确获取目标车道的车辆信息，图 3.1 展示了双车道交通场景下目标车道车辆检测示意图。




图 3.1 双车道场景车辆检测示意图

在双车道一侧的车道线上部署了地磁传感器，其任务是检测由目标车道车辆引起的地磁扰动，并通过一阶差分车辆检测算法处理地磁扰动数据，得到车辆的到达和离

开时间及车辆磁场信息。随后，通过 LoRa 设备将检测到的内容传输至基站，再通过 4G/5G 网络将其传输至云平台。

在应用基于一阶差分的状态机车辆检测算法进行单车道场景下的车辆检测时，检测准确率能够稳定在 98.8%。双车道场景中的车辆检测与单车道场景不同，传感器部署在双车道的一侧，也有可能检测到另一侧车道上的车辆通过，并错误地将另一侧车道上的车辆计入目标车道的车辆数中，导致车辆计数出现错误。车辆信息的检测错误可能会显著影响后续交通信息的分析和处理。因此，双车道场景下的车辆检测方案需要考虑邻道磁场的干扰问题。《中国标准高速公路车行道标准》规定双向四车道的车道宽度为 2×7.5 米，国家对公路每条机动车道的宽度提出了标准，三级以上多车道公路每条机动车道宽度为 3 米^[34]。对于本文使用的 RM3100 系列三轴地磁传感器，其检测范围是以地磁传感器为中心半径为 5 米的球形空间。这意味着部署在双车道一侧的传感器也可能检测到相邻车道行驶的车辆，从而导致目标车道上的交通流量信息出现错误。在交通网络中，双车道场景十分常见，也是研究多车道场景的基础。因此，对其进行研究有助于更好地掌握交通网络的运行情况，从而优化交通流动、改善交通安全。本章针对双车道场景设计了一种基于地磁传感器的邻道干扰排除方案，如图 3.2 所示。




图 3.2 基于地磁传感器的邻道干扰排除方案

本方案首先利用地磁传感器实现对磁场数据的采集，然后计算一阶差分数据，并通过检测车辆的到达和离开来截取车辆经过时引起的一段磁场扰动数据。最后，提取车辆磁场特征来区分目标车道和相邻车道上的车辆通行情况，以准确获取双车道交通场景下目标车道上的交通流量信息。

3.3 双车道车辆磁场建模与分析

3.3.1 车辆磁场的磁偶极子模型

车辆作为含有高铁磁性材料的载具，在运动过程中会对地磁场产生扰动，从而在车辆周围形成变化的磁场。根据电磁场理论，在铁磁运动物体相对于参考点的距离远大于物体本身的尺寸时，铁磁运动物体的磁场可以被简化为一个由磁偶极子产生的磁

场^[35]。在单传感器点目标模型中，一般定义距离点磁偶极子源 $\mathbf{r}$ 处的磁场感应强度计算式如式(3-1)和式(3-2)所示。

$$\mathbf{B} = \frac{\mu_0}{4\pi} \left[\frac{3(\mathbf{r} \cdot \mathbf{m})\mathbf{r}}{|\mathbf{r}|^5} - \frac{\mathbf{m}}{|\mathbf{r}|^3} \right] \quad (3-1)$$

$$J(\mathbf{m}, \mathbf{r}) = \frac{\mu_0}{4\pi|\mathbf{r}|^5} [3\mathbf{r}\mathbf{r}^T - |\mathbf{r}|^2 \mathbf{I}] \quad (3-2)$$

其中， μ_0 表示磁导率，其取值为 $4\pi \times 10^{-7} \text{ H/m}$ ， $\mathbf{r}$ 表示磁偶极子到传感器之间的距离取 $\mathbf{r} = \{x, y, z\}^T$ ， $\mathbf{m}$ 表示目标的磁偶极矩取 $\mathbf{m} = \{m_x, m_y, m_z\}^T$ 。图 3.3 中以地磁车辆检测模块为参考点，建立了一个空间直角坐标系，其中 X 轴方向与磁偶极子运动方向相同。




图 3.3 磁偶极子示意图

将 $\mathbf{r}$ 和 $\mathbf{m}$ 代入到式(3-1)中可以获得三轴磁场的矩阵形式，如式(3-3)所示。其中， $R = |\mathbf{r}|$ 并且 $\{B_x, B_y, B_z\}^T$ 表示 $\mathbf{B}$ 在每个正交方向上的分量。

$$\begin{bmatrix} B_x \\ B_y \\ B_z \end{bmatrix} = \frac{\mu_0}{4\pi R^5} \begin{bmatrix} 3x^2 - R^2 & 3xy & 3xz \\ 3xy & 3y^2 - R^2 & 3yz \\ 3xz & 3yz & 3z^2 - R^2 \end{bmatrix} \begin{bmatrix} m_x \\ m_y \\ m_z \end{bmatrix} \quad (3-3)$$

式(3-3)采用的是单磁偶极子逼近目标，然而这是一个相当粗略的近似，仅在参考点与铁磁运动物体之间的距离远大于物体本身尺寸的情况下适用。由于车辆在几何上

具有延伸,当车辆距离传感器的距离小于车身长度时,车身长度对磁场强度的影响不能忽略,因此车辆不能等效为一个磁偶极子源,需要引入多个磁偶极子以构建更为精确的扩展目标模型。假设用 d 个磁偶极子构成的模型对车辆进行等效,则模型产生的总磁场 $\mathbf{B}$ 的计算式如式(3-4)。其中, d 表示磁偶极子的个数, $\mathbf{m}_i$ 表示第 i 个磁偶极子的磁矩矢量, $\Delta\mathbf{r}_i$ 表示第 i 个磁偶极子距离目标中心 $\mathbf{r}$ 的相对距离。

$$\mathbf{B} = \sum_{i=1}^d J(\mathbf{m}_i, \mathbf{r}_i + \Delta\mathbf{r}_i) \mathbf{m}_i \quad (3-4)$$

车辆结构是进行车辆磁场建模的关键。在构建磁偶极子模型时,需要将复杂的车辆形状简化为相应的基本磁偶极子模型^{[36][37]}。首先,为了确定运动车辆自身磁场的具体情况,需要分析物体磁场在空间中的理论分布。如图 3.4 是将地磁传感器安置在车辆正下方时测得的车辆引起的磁场感应波形变化图,可以看出车辆的引擎、前轴和车体中心是引起磁场变化的三个重要位置。




图 3.4 磁场感应变化图

根据 Wahlström^[38]等人给出的结论本文采用三个磁偶极子的扩展目标模型，其中 3 个磁偶极子按照车辆行驶方向排列，以对车辆进行参数化。磁偶极子的间隔按照图 3.4 所述车辆结构分布，构成如图 3.5 所示的扩展目标模型示意图。需要注意的是，本文所涉及模型中每个磁偶极子都分布在车辆沿行驶方向的中轴线上，并且每个磁偶极子的磁矩矢量并不相同。为了简化分析的复杂度，本文假设所有磁偶极子距离地面的高度相同。




图 3.5 扩展目标模型示意图

式(3-1)到式(3-4)描述的是磁场强度随磁偶极子到传感器之间的距离 $\mathbf{r}$ 的变化关系。在实际数据采集的过程中，传感器节点记录的是磁场强度随时间的变化序列。本文考虑理想情况下，车辆在经过地磁传感器时沿着车道线做匀速直线运动，不会有任何垂直于行驶方向的位移。图 3.5 中的 $\Delta \mathbf{r}_i$ 由车辆结构决定， R 由初始距离 $\mathbf{r}_0 = \{x_0, y_0, z_0\}^T$ 和车速 $\mathbf{v} = \{v_x, v_y, v_z\}^T$ 决定，其中，速度的单位为米/秒，且有 $v_y = v_z = 0$ 。从初始位置 $\mathbf{r}_0$ 出发经过时间 t 的运动后磁偶极子到传感器之间的距离计算式如式(3-5)所示。

$$\begin{aligned}
 R &= |\mathbf{r}_0| + \mathbf{v}t \\
 x &= x_0 + v_x t \\
 y &= y_0 \\
 z &= z_0
 \end{aligned} \tag{3-5}$$

式(3-1)中提到的磁偶极子磁矩 $\mathbf{m}$ 与物体内部的磁性相关。通过对部分实际测试得到的车辆磁场数据的分析发现，在不同型号车辆在磁偶极子扩展目标模型中，磁偶极子的磁矩和各个磁偶极子之间的距离均不相同。因此，建立一个车辆通用的磁场模

型并不可行。一般情况下，只能针对特定类型的车辆，采集其原始磁场数据，用于计算多磁偶极子扩展目标模型中的各项参数。为了符合研究的要求，本文采集了一些具体车辆的磁场数据用于多磁偶极子扩展目标模型的仿真，以便进行必要的定性分析。

令 Θ 表示多磁偶极子扩展模型中需要估计的参数集合，其中包含各磁偶极子各自的磁矩。 $\mathbf{F}(k) = \{F_x(k), F_y(k), F_z(k)\}^T$ 表示实际测试得到的第 k 个时刻的三轴原始磁场数据， $\mathbf{B}(k, \Theta) = \{B_x(k, \Theta), B_y(k, \Theta), B_z(k, \Theta)\}^T$ 表示多磁偶极子扩展目标模型仿真得到的第 k 个时刻的三轴磁场数据。其中，测量磁场数据 $\mathbf{F}$ 与仿真磁场数据 $\mathbf{B}$ 是离散的时间序列，令 N_F 表示时间序列长度。需要定义一个损失函数来衡量测量值与仿真值之间的误差。通过最小化损失函数来寻找最优参数，让测量磁场数据 $\mathbf{F}$ 与仿真磁场数据 $\mathbf{B}$ 之间误差最小。

地磁传感器在 X、Y、Z 三轴上的测量噪声相互独立且具有相同的分布特性，服从均值为 0 的高斯分布，则测量误差的协方差矩阵 $\mathbf{Cov}$ 的表达式如式(3-6)所示。

$$\mathbf{Cov} = \begin{pmatrix} R_x & 0 & 0 \\ 0 & R_y & 0 \\ 0 & 0 & R_z \end{pmatrix} \quad (3-6)$$

其中， $R_i (i \in \{x, y, z\})$ 表示数据的样本方差，其表达式如式(3-7)和式(3-8)所示。

$$R_i = \frac{1}{N_F - 1} \sum_{k=1}^{N_F} (F_i(k) - \bar{F}_i)^2 \quad (3-7)$$

$$\bar{F}_i = \frac{1}{N_F} \sum_{k=1}^{N_F} F_i(k) \quad (3-8)$$

根据加权最小二乘法，得到损失函数 $C(\Theta)$ 的表达式如式(3-9)所示。

$$C(\Theta) = \sum_{k=1}^{N_F} (\mathbf{F}(k) - \mathbf{B}(k, \Theta))^T \mathbf{Cov}^{-1} (\mathbf{F}(k) - \mathbf{B}(k, \Theta)) \quad (3-9)$$

在最优问题的求解过程中，考虑实际情况，在进行参数估计时需要将参数范围限制在合理的范围内，相应的约束条件的表达式如式(3-10)所示。

$$h_i(\Theta) \leq 0 \quad (3-10)$$

其中, $i=1,2,\dots,N_{\Theta}$, N_{Θ} 表示参数集合中的参数数量。参数集合 Θ 中各参数的估计方法如式(3-11)所示。

$$\hat{\Theta} = \arg \min_{\Theta} C(\Theta) \quad (3-11)$$

通过式(3-11)可以得到多磁偶极子扩展目标模型中的最优参数集合 $\hat{\Theta}$ 。基于估计得到的磁矩参数值,可以根据需求对具体车辆在不同场景下的磁场波形进行仿真分析。

3.3.2 基于差分进化算法的参数估计

本文使用的最优化算法是差分进化算法 (Differential Evolution, DE)。由于本节仅使用该算法对磁偶极子模型相关参数进行计算,因此只对该算法进行简要介绍。

DE 算法旨在解决复杂的多变量优化问题,它模拟了自然进化的过程,通过不断演化种群来寻找目标函数的全局最小值^{[39][40]}。算法的基本步骤包括初始化种群、变异、交叉和选择。首先,随机生成一定数量的个体,每个个体代表问题的一个可能解。然后,通过个体之间的差异对每个个体进行变异操作,引入新的解以增加搜索空间的多样性。接着,利用交叉操作结合原个体和变异个体,生成新的个体。最后,新个体会被目标函数评价,并根据评价值来确定个体的适应度,然后根据适应度高低,选择一些优秀的个体作为父代,用于繁衍下一代个体。DE 算法在全局搜索方面表现出色,尤其适用于连续、非光滑以及高维度的优化问题。由于其简单和高效的优点,差分进化算法在各种领域的参数优化、机器学习模型调参等问题中得到广泛应用。

本节旨在对实际车辆的多磁偶极子扩展目标模型的参数进行估计。本小节仍沿用 3.3.1 节中确定的多个磁偶极子扩展模型,以 3 个磁偶极子按车辆行驶方向排成一排对车辆进行参数化。3 个磁偶极子分别位于车辆的引擎、前轴和车体中心。根据车辆类型可以确定车辆目标中心的起始位置 $\mathbf{r}_0 = \{x_0, y_0, z_0\}^T$, 以及 3 个磁偶极子距离目标中心的相对距离 $\Delta \mathbf{r}_i = \{\Delta \mathbf{r}_1, \Delta \mathbf{r}_2, \Delta \mathbf{r}_3\}^T$ 。选取的轿车和厢式货车的起始位置、3 个磁偶极子距离目标中心的相对距离以及行驶速度已知,如表 3.1 所示。

表 3.1 车辆参数值

车辆类型	$\mathbf{r}_0$	$\Delta \mathbf{r}_1$	$\Delta \mathbf{r}_2$	$\Delta \mathbf{r}_3$	v_x (m/s)
轿车	$\{-4.75, 1.71, 0.15\}$	$\{2.19, 0, 0\}$	$\{1.29, 0, 0\}$	$\{0, 0, 0\}$	13.58
厢式货车	$\{-4.97, 2.05, 0.8\}$	$\{3.22, 0, 0\}$	$\{1.89, 0, 0\}$	$\{0, 0, 0\}$	16.39

车辆起始位置 $\mathbf{r}_0 = \{x_0, y_0, z_0\}^T$ 中 x_0 表示车辆在 X 轴方向上与传感器节点的初始距离, y_0 表示车辆对称轴所在的直线与传感器节点之间的垂直距离, z_0 表示车辆的最小离地高度。 v_x 表示车辆沿 X 轴方向的行驶速度, 本小节仍沿用 3.3.1 节中的车辆匀速直线运动模型, 车辆与传感器节点在 X 轴方向上的距离表达式为式(3-5), 随车辆行驶时间与速度实时变化; 车辆与传感器节点之间的横向距离始终是 y_0 , 保持不变; 车辆与传感器节点之间的纵向距离始终是 z_0 , 由车辆的自身结构决定, 保持不变。图 3.6 和图 3.7 展示了选取的两辆车的车辆类型图以及实际测试得到的三轴原始磁场数据波形图。




图 3.6 轿车及磁场波形图




图 3.7 厢式货车及磁场波形图

确定表 3.1 中所述车辆参数后, 对需要估计的参数集合 Θ 中的所有参数以及符号表示进行说明, 如表 3.2 所示。

表 3.2 参数集合中的参数含义及约束条件

参数符号	参数含义	约束条件
$\mathbf{m}_1 = \{m_{x,1}, m_{y,1}, m_{z,1}\}$	1 号磁偶极子磁矩值，位于引擎。	$-500 \leq h_{1,2,3}(\Theta) \leq 500$
$\mathbf{m}_2 = \{m_{x,2}, m_{y,2}, m_{z,2}\}$	2 号磁偶极子磁矩值，位于前轴。	$-500 \leq h_{4,5,6}(\Theta) \leq 500$
$\mathbf{m}_3 = \{m_{x,3}, m_{y,3}, m_{z,3}\}$	3 号磁偶极子磁矩值，位于车体中心。	$-500 \leq h_{7,8,9}(\Theta) \leq 500$

基于上述分析和表 3.1 中的车辆参数值，利用 DE 算法估计出的轿车与厢式货车的 Θ 各参数如表 3.3 所示。

表 3.3 车辆参数集合估计结果

车辆类型	$\mathbf{m}_1$	$\mathbf{m}_2$	$\mathbf{m}_3$
轿车	$\{-263.93, 125.15, -259.69\}$	$\{-79.39, -345.79, -143.89\}$	$\{440.14, -168.11, 210.65\}$
厢式货车	$\{183.46, -90.03, -49.95\}$	$\{33.01, 399.89, -299.84\}$	$\{315.47, -266.76, -78.53\}$

根据表 3.1 和表 3.3 的所有参数构成的多磁偶极子模型，分别计算两辆车经过地磁传感器产生的三轴磁场波形，并将其与图 3.6 和图 3.7 所示的车辆磁场测量波形绘制在同一坐标系下，如图 3.8 和图 3.9 所示。




图 3.8 轿车的仿真与测量波形对比图




图 3.9 厢式货车的仿真与测量波形对比图

在图 3.8 和图 3.9 中，蓝色实线均为根据多磁偶极子模型计算得到的车辆仿真波形，黑色实线则为车辆的实测磁场波形。直观上看，仿真与真实测量的数据在整体变化趋势上没有明显的出入。为衡量仿真数据与测量数据的误差，本文引入一种常用的误差度量指标——均方根误差（Root Mean Square Error, RMSE），其计算式如式(3-12)所示。

$$RMSE = \sqrt{\frac{1}{3N_F} \sum_{i=x,y,z} \sum_{k=1}^{N_F} (B_i(k, \Theta) - F_i(k))^2} \quad (3-12)$$

其中涉及的符号均已在 3.3.1 小节中定义， N_F 是测量值序列的长度， $B_i(k, \Theta)$ 为参数集 Θ 对应多磁偶极子模型计算出的坐标轴 i 上的第 k 个数据， $F_i(k)$ 为与 $B_i(k, \Theta)$ 对应的实际测量值。使用单个磁偶极子模型计算轿车和厢式货车的仿真误差分别为 $RMSE_1 = 3.6210$ 和 $RMSE_2 = 12.5145$ ，利用式 (3-11) 计算轿车的仿真误差 $RMSE_3 = 0.5276$ ，厢式货车的仿真误差 $RMSE_4 = 0.8283$ ，对于轿车而言使用三个磁偶极子模型的误差相对于使用单个磁偶极子模型的误差减少了 85.43%，对于厢式货车而言使用三个磁偶极子模型的误差相对于使用单个磁偶极子模型的误差减少了 93.38%。

对于幅度为 10^2 量级的数据而言，大小不超过 1 的均方根误差是可以接受的，故可以利用上述得到的两组多磁偶极子模型进行所需场景的车辆磁场建模。根据估计得到的磁矩 $\mathbf{m}_i$ ，结合式(3-4)便可以计算得到不同车辆在经过地磁传感器时产生的总磁场。有了对车辆等效磁偶极子模型的完整描述，通过改变 $\mathbf{m}_i$ 、 y_0 、 v_x 、 $\Delta \mathbf{r}_i$ 等参数的值，就可以对不同类型车辆在不同场景下的磁场数据进行仿真。

3.3.3 双车道车辆的一阶差分磁场波形仿真

在本小节中进行了基于车辆等效多磁偶极子模型的仿真实验，以研究目标车道和相邻车道车辆经过地磁传感器时的磁场波形特征。在多磁偶极子模型中，同一车辆在目标车道行驶和在相邻车道行驶的区别在于车辆和地磁传感器在 Y 方向上的垂直距离。而不同车辆在目标车道行驶和在相邻车道行驶的区别在于车辆和地磁传感器在 Y 方向上的距离以及车辆的磁矩值。另一方面，车辆沿 X 轴方向做匀速直线运动，为了观察完整的车辆磁场波形而非单个采样点处的磁场强度值，需要结合式(3-5)对车辆的完整磁场波形进行仿真。因此，本小节专注于双车道交通场景下目标车道车辆与相邻车道车辆的磁场波形仿真，并通过调整车辆和地磁传感器在 Y 方向上的距离以及车辆的磁矩值，对不同车辆在不同车道行驶时的一阶差分磁场波形进行定性分析，用于初步了解不同车道车辆的磁场变化情况，为进一步的定量分析提供参考。

3.3.1 小节和 3.3.2 小节是对车辆原始磁场数据的分析,在此基础上,需要对原始磁场数据的一阶差分值进行分析。令 $\mathbf{D}_k$ 表示 k 时刻磁场感应强度的一阶差分矢量, $\mathbf{B}_{k+1}$ 和 $\mathbf{B}_k$ 分别表示 $k+1$ 时刻和 k 时刻的磁场感应强度矢量,定义磁场感应强度的一阶差分计算式如式(3-13)所示。

$$\mathbf{D}_k = \mathbf{B}_{k+1} - \mathbf{B}_k \quad (3-13)$$

根据式(3-3),得到 $\mathbf{B}_{k+1}$ 和 $\mathbf{B}_k$ 的磁场感应强度表达式如式(3-14)和式(3-15)所示。

$$\mathbf{B}_{k+1} = \frac{\mu_0}{4\pi R_{k+1}^5} \begin{bmatrix} 3x_{k+1}^2 - R_{k+1}^2 & 3x_{k+1}y & 3x_{k+1}z \\ 3x_{k+1}y & 3y^2 - R_{k+1}^2 & 3yz \\ 3x_{k+1}y & 3yz & 3z^2 - R_{k+1}^2 \end{bmatrix} \begin{bmatrix} m_x \\ m_y \\ m_z \end{bmatrix} \quad (3-14)$$

$$\mathbf{B}_k = \frac{\mu_0}{4\pi R_k^5} \begin{bmatrix} 3x_k^2 - R_k^2 & 3x_k y & 3x_k z \\ 3x_k y & 3y^2 - R_k^2 & 3yz \\ 3x_k y & 3yz & 3z^2 - R_k^2 \end{bmatrix} \begin{bmatrix} m_x \\ m_y \\ m_z \end{bmatrix} \quad (3-15)$$

其中, $k+1$ 时刻和 k 时刻的磁偶极子相对于地磁传感器的直线距离分别为 R_{k+1} 和 R_k 。本文使用的地磁传感器的数据采样频率为 100Hz, 两点之间的时间间隔为 10ms, 根据式(3-5), 得到 x_{k+1} 和 x_k 的关系式如式(3-16)所示。

$$x_{k+1} = x_k + 0.01v_x \quad (3-16)$$

以 X 轴为例, 将式(3-13)和(3-14)的 X 轴分量代入式(3-12)中, 则 k 时刻 X 轴磁场感应强度的一阶差分计算式如式(3-17)所示。

$$D_{x,k} = \frac{\mu_0}{4\pi R_{k+1}^5} \left[(3x_{k+1}^2 - R_{k+1}^2) \cdot m_x + 3x_{k+1}y \cdot m_y + 3x_{k+1}z \cdot m_z \right] - \frac{\mu_0}{4\pi R_k^5} \left[(3x_k^2 - R_k^2) \cdot m_x + 3x_k y \cdot m_y + 3x_k z \cdot m_z \right] \quad (3-17)$$

为简化上式, 提取常量系数 $\frac{\mu_0}{4\pi}$, 用 w 进行表示, 将 $R_k^2 = x_k^2 + y_k^2 + z_k^2$ 代入到式(3-16)的分子部分, 得到式(3-18)。

$$D_{x,k} = \frac{w}{R_{k+1}^5 R_k^5} [[2(R_k^5 x_{k+1}^2 - R_{k+1}^5 x_k^2) + (R_{k+1}^5 - R_k^5)(y^2 + z^2)] \bullet m_x + 3y(R_k^5 x_{k+1} - R_{k+1}^5 x_k) \bullet m_y + 3z(R_k^5 x_{k+1} - R_{k+1}^5 x_k) \bullet m_z] \quad (3-18)$$

同理, 可得 k 时刻 Y 轴和 Z 轴磁场感应强度的一阶差分计算式如式(3-19)和式(3-20)所示。

$$D_{y,k} = \frac{w}{R_{k+1}^5 R_k^5} [(x_k^2 R_{k+1}^5 - x_{k+1}^2 R_k^5) + (R_k^5 - R_{k+1}^5)(2y^2 - z^2)] \bullet m_y + 3y(R_k^5 x_{k+1} - R_{k+1}^5 x_k) \bullet m_x + 3yz(R_k^5 - R_{k+1}^5) \bullet m_z] \quad (3-19)$$

$$D_{z,k} = \frac{w}{R_{k+1}^5 R_k^5} [(x_k^2 R_{k+1}^5 - x_{k+1}^2 R_k^5) + (R_k^5 - R_{k+1}^5)(2z^2 - y^2)] \bullet m_z + 3z(R_k^5 x_{k+1} - R_{k+1}^5 x_k) \bullet m_x + 3yz(R_k^5 - R_{k+1}^5) \bullet m_y] \quad (3-20)$$

双车道交通场景下邻道干扰问题的难点在于, 对大型车在相邻车道行驶时产生的磁场一阶差分与小型车在目标车道行驶时产生的磁场一阶差分之间区分度的研究。需要分析三轴磁矩与车辆和地磁传感器在 Y 方向上的距离, 这两个影响因素对一阶差分数值的影响程度。从式(3-17)可得, k 时刻 X 轴磁场感应强度的一阶差分在车辆与地磁传感器之间的距离参数、行驶速度不变的情况下与三轴磁矩呈线性关系。而在保证其余参数不变, 仅分析车辆和地磁传感器在 Y 方向上的距离变化对 k 时刻 X 轴磁场一阶差分的影响, 式(3-17)分母中的 $R_{k+1}^5 R_k^5$ 与三个距离参数均呈 10 次方增长的关系, 其对一阶差分值的影响相比于三轴磁矩要大很多。

式(3-17)至式(3-19)描述了某一时刻磁场感应强度的一阶差分如何随着车辆位置和三轴磁矩的变化而变化的动态特性。在实际的数据采集过程中, 传感器节点得到的是磁场感应强度随时间变化的一系列数据点的集合, 相应计算得到的也是一阶差分的时间序列。

根据轿车和厢式货车的多磁偶极子模型, 以及式(3-12)到式(3-15)对磁场感应强度的一阶差分的定义, 仿真得到轿车和厢式货车磁矩条件下三轴磁场感应强度的一阶差分序列变化图, 如图 3.10、图 3.11 和图 3.12 所示, 图左为轿车的一阶差分序列变化图, 图右为厢式货车的一阶差分序列变化图。

三维图中 X 轴表示车辆与地磁传感器在 X 方向上的距离, Y 轴表示车辆与地磁传感器在 Y 方向上的距离, Z 轴表示磁场感应强度的一阶差分。本文使用的地磁传感器检测范围是以地磁传感器为中心半径为 5 米的球形空间, 故仿真时车辆和地磁传感器在 X 方向上的距离取值范围设置为 $[-5, 5]$ 。国家对公路每条机动车道的宽度提出

了标准，三级以上双车道公路每条机动车道宽度为 3.5~3.75 米，即双车道的车道宽度为 7~7.5 米。在多磁偶极子扩展目标模型中，磁偶极子分布在车辆沿行驶方向的中轴线上，考虑到轿车车身宽度为 1.75 米，仿真中磁偶极子模型中心和地磁传感器在 Y 方向上的距离范围设定为[0.8,5.5]。




图 3.10 轿车和厢式货车 X 轴磁场差分变化图




图 3.11 轿车和厢式货车 Y 轴磁场差分变化图




图 3.12 轿车和厢式货车 Z 轴磁场差分变化图

从图 3.10 到图 3.12 可以看出,磁偶极子和地磁传感器在 Y 方向上的距离增大时,各轴的磁场感应强度的一阶差分衰减比较明显;对比轿车和厢式货车,当二者与地磁传感器在 Y 方向上的距离相同时,轿车的一阶差分相比与厢式货车的一阶差分也有一定的减小。为了定量对比轿车与厢式货车在同一 Y 距离上的衰减程度,在图中标出了轿车和厢式货车 $y = 3.8$ 米时各轴磁场感应强度的一阶差分序列幅值,即车辆中轴线与双车道路面中心线重合行驶时各轴磁场感应强度的一阶差分序列幅值,上述标点的三轴坐标如表 3.4 所示。

表 3.4 标点三轴坐标值

标点 坐标轴	$Q_{x,1}$	$Q_{x,2}$	$Q_{y,1}$	$Q_{y,2}$	$Q_{z,1}$	$Q_{z,2}$
X 轴坐标	0.3	0.2	-1.3	1.7	0.1	0.9
Y 轴坐标	3.8	3.8	3.8	3.8	3.8	3.8
Z 轴坐标	5.17	5.65	5.05	4.77	-0.91	-1.13

由表 3.4 可以得出,当车辆中轴线与双车道路面中心线重合行驶时,轿车和厢式货车的各轴磁场感应强度的一阶差分序列幅值已经衰减到了同一程度,即当车辆未在目标车道行驶时,即使是磁矩较大的厢式货车,其磁场感应强度的一阶差分序列幅值也衰减到了较小的水平。通过以上分析得出结论,目标车道和相邻车道车辆的磁场感应强度一阶差分序列在波动范围上存在显著差异,因此需要选择有效磁场特征来实现双车道交通场景下的邻道干扰排除。

3.4 双车道的邻道干扰排除算法

3.4.1 磁场特征及分类算法选择

波形分析在多个领域中有着广泛的应用,涵盖了从信号处理到工程控制的广泛范围^[41]。常见的描述和衡量波形振幅的特征包括峰-峰值、标准差、均方根值、平均能量。每个特征都有其独特的优缺点,根据本文的研究目的和波形特性进行分析,选择合适的特征。本文用 P 表示峰-峰值,令 $V_{\max}$ 表示一段波形的最大峰值,令 $V_{\min}$ 表示一段波形的最小谷值,则峰-峰值 P 的计算方法如式(3-21)所示。峰-峰值直观地反映了波形的全振幅,但对于包含离群值的数据较为敏感,因为它只依靠最大峰值和最小谷值两个点进行计算,没有考虑波形的整体形状。在本文需要考虑波形整体振幅的条件下,这一特征并不适用。

$$P = V_{\max} - V_{\min} \quad (3-21)$$

本文用 σ 表示标准差，令 n 表示一段波形的采样点数，令 x_i 表示一段波形中第 i 个采样点的磁场感应强度，令 $\bar{x}$ 表示一段波形的磁场感应强度均值，则标准差 σ 的计算方法如式(3-22)所示。标准差提供了波形振幅的离散程度，可以较好地处理正负振幅。然而，根据第二章对一阶差分车辆检测算法的介绍，本文在使用一阶差分时关注的是振幅的大小，而不考虑其正负方向，所以标准差不符合本文的使用需求。

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (3-22)$$

本文用 RMS 表示均方根值，其计算方法如式(3-23)所示。均方根值直观地反映了波形整体的振动程度，且平方操作确保了对所有振幅的正负都有很好的处理，更符合本文的使用需求。

$$RMS = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \quad (3-23)$$

本文用 E_{ave} 表示平均能量，其计算方法如式(3-24)所示。平均能量提供了对整个波形能量分布的全局视角，同时具有均方根值中涉及的振幅的平方和。相比于均方根值，平均能量省略了计算中的开方操作，计算更加简便高效。

$$E_{ave} = \frac{1}{n} \sum_{i=1}^n x_i^2 \quad (3-24)$$

因此，在双车道交通场景下，邻道干扰排除问题可以转化为基于三轴一阶差分平均能量大小进行目标车道车辆和相邻车道车辆区分的二分类问题。

分类机制在机器学习领域扮演着至关重要的角色，其核心任务是将数据集中的样本划分为不同的类别^[42]。这一机器学习技术的广泛应用包括医学诊断、金融欺诈检测、交通流量监测以及自然语言处理等多个领域^{[43][44]}。通过学习模型，分类机制可以从已知类别的训练数据中提取规律，从而对新数据进行有效的分类和预测。不同的分类方法具有各自独特的特点，适用于不同类型的问题。逻辑回归简单且计算效率高，在问题的初步探索中具有一定优势，但对于非线性关系的建模能力较弱，无法很好地应对

复杂的数据模式，在多维数据下表现不佳。支持向量机在高维空间中表现强大，对于多维振动数据的分割能力强，但在处理大规模数据集时计算开销较大，在实时性要求高的场景下效率不高。决策树对异常值相对鲁棒，但容易过拟合，可能在对复杂的地磁扰动数据模式拟合时效果有限。随机森林通过集成多个决策树提高性能，但是计算成本较高，不适用于计算资源受限的环境。投票机制简单直观，易于理解和实现，对于多维数据的综合考虑具有优势，但是对于异常值敏感，需要谨慎设定投票机制和阈值。神经网络适用于大规模和复杂问题，但在小规模数据集中可能出现过拟合，且模型结构复杂，调参难度大。在这些方法中，投票机制通过简单而直观的方式，将多个基学习器的输出综合起来。对于简单的二分类问题，尤其是基于三轴磁场一阶差分平均能量大小的二分类任务，投票机制在综合考虑多轴信息的同时，保持了模型的直观性和可解释性。

3.4.2 分类算法设计

投票机制是一种集成学习方法，其原理是基于对多个分类器的输出进行投票来做出最终的决策。在二分类问题中，通常使用奇数个基分类器，以确保有明确的多数派。投票机制分为硬投票和软投票两种形式。在硬投票中，每个基分类器投出一个类别的票，最终的类别是获得最多投票的类别，其表达式如式(3-25)所示。其中， $\hat{y}$ 表示最终的预测类别， $c_1, c_2, \dots, c_k$ 表示基分类器的输出类别， mode 表示取众数。

$$\hat{y} = \text{mode}(c_1, c_2, \dots, c_k) \quad (3-25)$$

在软投票中，每个基分类器投出的不是类别标签，而是类别的概率值。最终的类别是通过概率加权平均后得到的，其表达式如式(3-26)所示。其中， $\hat{y}$ 表示最终的预测类别， w_j 表示第 j 个分类器的权重， p_{ij} 表示第 i 个样本被分类为类别 j 的概率。

$$\hat{y} = \arg \max_i \sum_{j=1}^k w_j p_{ij} \quad (3-26)$$

本文的最终目标是对车辆行驶车道进行二分类，即判断其行驶在目标车道还是相邻车道。硬投票适用于基分类器输出相同类型结果的情况，而在这个问题中，每个基分类器都输出目标车道行驶或相邻车道行驶类别标签。因此，硬投票保持了分类的一致性，最终的决策是通过多数票决定的。另外，目标车道行驶和相邻车道行驶的分类问题相对而言是一个简单的问题，采用硬投票方法能够在保持模型简单和直观的同时，实现对问题的有效分类。结合本文所述应用场景的特点，选择使用硬投票机制设

计目标车道行驶和相邻车道行驶车辆的分类器。

在此基础上, 本文将阈值分类作为硬投票机制的基分类器。在阈值分类中, 基于单一特征的取值与预先设定的阈值之间的大小关系进行决策。具体而言, 当某个轴上的平均能量大于阈值时, 基分类器判定样本为目标车道行驶车辆; 反之, 当平均能量小于阈值时, 基分类器判定样本为相邻车道行驶车辆。硬投票机制整合了 X、Y、Z 三轴各自阈值分类器的决策, 采用多数投票的原则确定最终的分类结果。如果两个及以上阈值分类器判定样本为目标车道车辆, 则整体硬投票机制将样本分类为目标车道车辆; 反之, 则分类为相邻车道车辆。就本文所述应用场景, 硬投票机制的表达式如式(3-27)所示。

$$\hat{y} = \begin{cases} 1 & \text{if } \sum_{i=1}^N c_i > \frac{N}{2} \\ 0 & \text{if } \sum_{i=1}^N c_i \leq \frac{N}{2} \end{cases} \quad (3-27)$$

其中, N 表示基分类器的数量, 在本文所述应用场景中 $N=3$, 即 X、Y、Z 三轴磁场感应强度的一阶差分序列各对应一个基分类器。 c_i 表示 i 轴基分类器的输出, 其表达式如式(3-28)所示。

$$c_i = \begin{cases} 1 & \text{if } E_{i,ave} > T_i \\ 0 & \text{if } E_{i,ave} \leq T_i \end{cases} \quad (3-28)$$

其中, $E_{i,ave}$ 表示 i 轴的平均能量, T_i 表示 i 轴的平均能量阈值。

上述分类算法中, 需要确定的参数为阈值 T_i ($i \in \{x, y, z\}$), 在后续实验过程中会给出 T_i 的确定方法。

3.5 实验测试结果与性能分析

3.5.1 实验场景介绍

本次研究的重点在于探究地磁传感器在双车道交通场景下对目标车道车辆数的检测精度。为了全面评估算法的准确性, 测试选择了西安市内一条同向双车道道路作为测试场景。这条道路的选择考虑到其代表性和实际交通情况, 能够提供真实且符合本文实验场景的测试环境。在测试过程中, 为了覆盖尽可能大的车流量和广泛的车速范围, 选择了下午三点半到五点半这一时段进行测试。此外, 所选道路涵盖了多种车

辆类型。该时间段是西安市内车流量相对较大的时段，这有助于更准确地评估车辆检测系统的性能表现。

如图 3.13 所示，在实验测试中，使用的设备有摄像机、笔记本电脑、地磁传感器、基站。地磁传感器部署在同向双车道左侧的车道线上，所选道路宽度为 3.5m，道路的车速从 10km/h 到 70km/h 不等，道路的车流量从 300veh/h 到 2400veh/h 不等。



图 3.13 实验测试场景图

由于传感器的感应半径为 5m 左右，本文对目标车道进行车流量测试的同时，也会检测到部分相邻车道的车辆。在测试过程中，使用摄像机对双车道上的实际场景进行了视频记录。笔记本与地磁传感器通过串口线连接，通过串口调试助手接收传感器采集到的数据，该数据既包括三轴原始磁场数据，还包括检测到的车辆到达离开时间。在测试完成后，对照采集的视频对地磁传感器检测到的车辆到达时间和离开时间进行核对，统计对目标车道车辆的检测情况。

3.5.2 测试结果分析

本文根据实际采集的大量双车道车辆数据进行了分析。其中，目标车道车辆磁场数据有 1372 组，被地磁传感器的车辆检测算法检测到的相邻车道车辆磁场数据有 1231 组。首先，按照式(3-12)计算得到各组 X、Y、Z 三轴磁场感应强度的一阶差分序列，再根据式(3-21)计算得到各轴一阶差分序列的平均能量，统计得到各轴平均能量的分布情况，如图 3.14 所示。从图 3.14 中可以看出，两组数据的箱体位于不同的高度，箱体的下边界、中位数线和上边界分别对应它们的下四分位数、中位数和上四分位数，展现了两组数据中心趋势的不同。另外，箱体没有重叠部分，这意味着目标车道和相邻车道车辆数据的三轴平均能量在中位数和四分位数上存在明显的区别。根

据上述数据统计, 本文选取相邻车道箱体上边界与目标车道箱体下边界之间的一阶差分平均能量作为邻道干扰排除算法的判断阈值, 参数设置如表 3.5 所示。




图 3.14 目标车道和相邻车道实测数据平均能量的箱型图

表 3.5 邻道干扰排除算法参数设置

参数	参数名称	参数设置
T_x	X 轴磁场强度一阶差分的平均能量阈值	9
T_y	Y 轴磁场强度一阶差分的平均能量阈值	18
T_z	Z 轴磁场强度一阶差分的平均能量阈值	2

在这些参数取值下, 为了测试双车道交通场景下邻道干扰排除算法的准确性, 本文在同一路段采集了 5 组数据, 每组数据中目标车道的车辆数据有 300 组, 被地磁传感器的车辆检测算法检测到到达离开的相邻车道车辆数据有 230 组。统计得到的目标车道误检率以及相邻车道误检率如表 3.6 所示。其中, 目标车道误检率代表将实际从目标车道经过的车辆检测为相邻车道经过的车辆数与目标车道总车辆数 300 的比值, 相邻车道误检率代表将实际从相邻车道经过的车辆检测为目标车道经过的车辆数与相邻车道总车辆数 230 的比值。

表 3.6 目标车道与相邻车道分类情况

组别	目标车道误检率	相邻车道误检率
第 1 组	0.33%	1.74%
第 2 组	0.67%	0.87%
第 3 组	0.00%	1.30%
第 4 组	0.33%	1.30%
第 5 组	0.00%	2.17%

从上述结果可以看出,双车道交通场景下相邻车道车辆经过,并且被双车道一侧的传感器检测到,从而将相邻车道车辆经过误判为目标车道车辆经过的误检测并不是偶然情况。因此,Taghvaeeyan 等人^[17]采取的方式是在地磁传感器旁边间隔较近距离再放置一个传感器节点,使用相邻的两个地磁传感器检测到的磁场数据特征差来对车辆数量进行判断,该方法可以修正 91%的误检测,但是这种方式增加了传感器数量,提高了检测成本。张等人^[45]结合车辆速度和磁场峰值来判别邻道干扰的情况,由于特征提取单一,该方法可以修正 89%的误检测。本章提出的方法仅使用单个信标实现对目标车道车辆信息的准确统计,并结合双车道场景以及磁偶极子模型对特征的合理性进行了分析,实验结果表明该方法在最大车均延误小于 145s 且最大排队时间指数小于 2.1 的中度拥堵情况下可以修正 98%的相邻车道误检测,因此本章的研究内容在实际应用中具有重要的意义和价值。

3.6 本章小结

本章主要研究了双车道交通场景下的邻道干扰排除算法。针对部署在同向双车道一侧车道线上的地磁传感器可能会误将相邻车道的车辆检测为目标车道车辆,导致车辆信息获取错误的问题,首先通过磁偶极子建立的车辆模型结合双车道场景对上述误检测问题进行了分析。证明了相较于目标车道车辆,相邻车道车辆的磁场感应强度的一阶差分序列在幅值上有明显的衰减。在对波形振幅的多个特征进行对比分析后,最终选择 X、Y、Z 三轴平均能量作为判别目标车道车辆和相邻车道车辆的特征,并将阈值分类作为基分类器设计了硬投票机制。最后,为了验证算法在实际场景中的有效性和可行性,收集了真实道路上的数据进行测试。经过测试,本方案可以实现双车道交通场景下的邻道干扰排除,从而获取准确的车流量信息。

第四章 车型分类算法研究

4.1 引言

随着城市交通的不断发展，智慧交通系统对车型分类检测的需求日益增加。地磁传感器的相对低成本、简便的安装和维护使得基于地磁传感器的车型分类技术在城市交通系统中得以广泛应用。这一技术的出现填补了以往传感器网络和视觉系统存在的空白。基于单个地磁传感器的车型分类满足了成本效益和高效性的迫切需求，为智慧交通系统和交通管理提供了一种更为可行的解决方案。这项研究的意义在于推动车型分类技术的普及，为城市交通管理提供更精准、经济的监测手段，使其成为城市交通管理中不可或缺的工具，为未来交通系统的发展奠定坚实基础。

本文采用第二章和第三章所述的一阶差分检测算法和邻道干扰排除算法，实现了对目标车道车流量的准确检测。在此基础上，本章节从地磁环境基线出发，提取车辆引起的磁场扰动。根据获取到的车辆磁场扰动数据，分析了不同车辆类型引起的磁场扰动波形，从中提取了车型分类特征，并根据特征配对消除算法对特征进行筛选，从而根据筛选得到的特征集设计了基于 SoftMax 回归的车型分类算法。最后，本章通过实际测试对所设计算法的精度和稳定性进行了评估。

4.2 地磁环境基线更新方法

4.2.1 基线更新概述

在实际应用中，地磁传感器采集到的三轴磁场数据通常同时受到环境磁场和车辆引起的磁场扰动的影响。在此背景下，本文旨在利用地磁传感器采集的磁场数据实现对车辆类型的自动识别。为了达到这一目标，需要从原始数据中消除环境磁场的影响，保留由车辆引起的磁场扰动。这种磁场扰动的独特特征将被用作车型分类的依据，为智慧交通系统的进一步发展提供有力支持。磁场具有可叠加性，即信标采集到的原始磁场是环境磁场和干扰磁场叠加的结果。根据观察，环境磁场在没有车辆经过时保持相对稳定，但是在较长时间内存在缓慢漂移。令 $\mathbf{F}_{env}(k)$ 表示 k 时刻的三轴环境基线，在磁场稳定时，应当对环境基线 $\mathbf{F}_{env}(k)$ 进行实时更新和记录，这个过程称为环境基线的更新。

基线更新的正确与否取决于磁场稳定判断的准确性。在没有车辆经过时，磁场应该处于纯环境水平，当一定时间窗长度的有车概率都小于基线更新阈值时，应当进行基线更新。然而，对车辆经过时磁场数据的观察发现，对于正常速度驶过的车辆，磁

场变化较快,不会触发基线误更新。对于停靠车辆的减速停靠和启动离开以及缓行车辆的经过等情况,基线会有一定的跟随。如果跟随太多,则会导致环境基线与真实环境磁场水平差距太大。因此,有车概率较小并不意味着磁场的稳定,只能说明此时磁场变化缓慢。应当调整基线更新的逻辑,进一步加强调用基线更新子程序的条件,不应只在有车概率小于阈值 θ_{arr} 的时候进行基线更新。

4.2.2 磁场稳定性判断的特征提取

为此,本文针对稳定的环境磁场与有车经过时的磁场进行了对比分析,提取能够衡量磁场稳定的特征,具体如下。

令 $R_i^L(k)$ 表示从 k 时刻开始时间窗内 i 轴原始磁场数据的极差, $\mathbf{F}_i^L(k)$ 表示从 k 时刻开始时间窗内的 i 轴原始磁场数据,其中 $i \in \{x, y, z\}$,时间窗长度为 L ,则极差 $R_i^L(k)$ 计算式如式(4-1)所示。

$$R_i^L(k) = \max\{\mathbf{F}_i^L(k)\} - \min\{\mathbf{F}_i^L(k)\} \quad (4-1)$$

令 $M_i^L(k)$ 表示从 k 时刻开始时间窗内的 L 个 i 轴原始磁场数据 $\mathbf{F}_i^L(k)$ 中所有元素的均值与从 $k-L$ 时刻开始时间窗内的 L 个 i 轴原始磁场数据 $\mathbf{F}_i^{k-L}(k)$ 中所有元素的均值之差的绝对值。为方便表述,称 $M_i^L(k)$ 为磁场均值差,其计算式如式(4-2)所示。

$$M_i^L(k) = |\text{mean}\{\mathbf{F}_i^L(k)\} - \text{mean}\{\mathbf{F}_i^{k-L}(k)\}| \quad (4-2)$$

为了综合考虑三轴磁场的极差情况,应当对三轴磁场极差进行融合,本文采用的是归一化加权求和的方法。选择归一化加权的原因在于,各轴的波动范围不尽相同,直接将计算出的极差进行求和处理,容易导致波动范围较大的特征在判断是否更新基线时起主导作用,影响基线更新的效果。因此,可以基于各轴原始数据的波动程度对各轴极差赋予不同的权重。能够反映波动剧烈程度的常用特征就是数据标准差,对于标准差较大的坐标轴,其权重应当较小。基于以上分析,给出如下加权方法。

在自然环境中,三轴磁场的分布通常服从正态分布。令环境磁场数据的 X 轴标准差、 Y 轴标准差和 Z 轴标准差分别为 σ_x 、 σ_y 、 σ_z , $R_{sum,k}$ 表示三轴极差加权求和得到的融合值, $M_{sum,k}$ 表示三轴磁场均值差加权求和得到的融合值。各轴环境磁场数据的标准差越大,对应的权重越小,为了使加权融合后的值与融合前的值处在同一水平,对三个加权系数进行归一化,确保各个权值的和为1。令 W_i 表示 i 轴环境磁场数据极差的权重系数,其中 $i \in \{x, y, z\}$,其计算式如式(4-3)所示。

$$W_i = \frac{\frac{1}{\sigma_i}}{\frac{1}{\sigma_x} + \frac{1}{\sigma_y} + \frac{1}{\sigma_z}} = \frac{\sigma_x \sigma_y \sigma_z}{\sigma_i (\sigma_y \sigma_z + \sigma_x \sigma_z + \sigma_x \sigma_y)} \quad (4-3)$$

由此，得到融合值的计算式如式(4-4)和式(4-5)所示。

$$R_{sum,k} = W_x R_x^L(k) + W_y R_y^L(k) + W_z R_z^L(k) \quad (4-4)$$

$$M_{sum,k} = W_x M_x^L(k) + W_y M_y^L(k) + W_z M_z^L(k) \quad (4-5)$$

当磁场稳定时，时间窗内三轴磁场在幅值上不会有太大的浮动，三轴磁场极差加权求和得到的融合值 $R_{sum,k}$ 要小于一定阈值，令 RTH_R 表示三轴磁场极差加权融合值的阈值；同时三轴磁场均值差加权求和得到的融合值 $M_{sum,k}$ 也要小于一定阈值，令 RTH_M 表示三轴磁场均值差加权融合值的阈值。相比于磁场极差，磁场均值差能提供不同的信息。具体来说，极差衡量的是当前一段时间窗内磁场的波动范围，而磁场均值差对比的是当前时间窗与历史时间窗内磁场水平的差值，用以区分缓行车辆的磁场缓慢变化与环境磁场的缓慢漂移。故考虑将两个特征融合起来进行磁场稳定与否的判断，在判断稳定时，即保证了当前时刻对应时间窗内磁场浮动较小，也保证了当前时间窗与历史时间窗内磁场水平差距不大。

基线更新的过程是在第二章提到的于一阶差分车辆检测算法的 S1 无车状态下进行的。在 S1 状态下，当 $R_{sum,k} < RTH_R$ 并且 $M_{sum,k} < RTH_M$ 时，认为此时磁场稳定，计算当前时刻对应长度为 L 的时间窗内的磁场均值，将其作为当前时刻的环境基线。

时间窗长度 L 的确定方法如下。更新基线需要有两个考虑，一是要保证环境基线在较长一段时间内的稳定性，因为环境基线本身是一个缓慢变化的情况，二是要保证基线对环境磁场有较好的跟随性。本文需要统计在上述基线更新方案下采取不同的采样点数 L 时，时间窗内环境基线和采集的环境磁场数据在方差上的不同，从而选取最优的采样点数 L 。最优的采样点数应该能够保证环境基线的稳定性，并且具有较好的跟随性。

令 σ_{env}^2 表示在时间窗 L 条件下三轴环境磁场数据关于三轴环境基线的方差，用于衡量当前环境基线相较于原始环境磁场数据的偏离程度。 σ_{env}^2 越大，说明环境磁场数据偏离基线的程度越大；反之则说明环境磁场数据偏离基线的程度越小。 σ_{env}^2 的计算方式如式(4-6)所示。其中， n 表示数据序列的长度， $\mathbf{F}(k)$ 表示 k 时刻的三轴环境磁场值， $\mathbf{F}_{env}(k)$ 表示窗长度 L 条件下更新的 k 时刻的三轴环境基线。

$$\sigma_{env}^2 = \frac{1}{n} \sum_{k=1}^n (\mathbf{F}(k) - \mathbf{F}_{env}(k))^2 \quad (4-6)$$

显然，当用于进行基线更新的时间窗长度 L 取不同值时，对应的 σ_{env}^2 也会不同，故可以通过计算 L 取不同值时 σ_{env}^2 的取值，绘制 σ_{env}^2 随 L 变化的关系曲线，寻找时间窗长度 L 的合适取值。

4.3 车型分类特征分析

4.3.1 车型分类特征提取

地磁传感器通常用于检测地面上的磁场变化，以识别车辆的存在和移动，但其分辨率可能不足以实现高精度的细分。为了完善地磁车辆检测系统，为其提供更多的车辆信息，本文结合国家公共安全行业标准 GA 802-2019 道路交通管理关于机动车分类的标准^[46]以及机动车的车轴数，将机动车分为大、中、小三大类，分类标准如表 4.1。

表 4.1 车型分类标准

车型	车型分类说明
小型车	微型、小型、中型载客汽车（车长 $\leq 6000\text{mm}$ 且乘坐人数 ≤ 19 ）、载货汽车（车长 $\leq 6000\text{mm}$ 且总质量 $\leq 4500\text{kg}$ ，两轴四轮）、三轮汽车、摩托车
中型车	大型载客汽车（车长 $\geq 6000\text{mm}$ 或者乘坐人数 ≥ 20 ，两轴四轮）、载货汽车（车长 $\geq 6000\text{mm}$ 或总质量 $\geq 4500\text{kg}$ 且 $\leq 12000\text{kg}$ 或车长小于等于 6000mm 的两轴六轮）、专项作业车（两轴四轮或六轮）、牵引车
大型车	大型载客汽车（车长 $\geq 6000\text{mm}$ 或者乘坐人数 ≥ 20 ，两轴六轮及以上）、载货汽车（总质量 $\geq 12000\text{kg}$ ，三轴六轮及以上）、专项作业车（三轴六轮及以上）、牵引车拉挂车

本章在表 4.1 的分类标准基础上，研究了基于地磁传感器的车型分类算法。首先，采用基于一阶差分的状态机车辆检测算法检测车辆的到达和离开，然后通过邻道干扰排除算法剔除相邻车道车辆，以获取目标车道车辆的原始磁场数据。其次，通过将原始磁场数据减去地磁环境基线来获得车辆引起的磁场扰动，并通过不同特征来表征车辆的磁场扰动，以获取用于车辆分类算法训练和测试的特征集。图 4.1 是 9 辆车的车辆磁场分割效果示意图，1 到 3 号波形为小型车车辆磁场信号，4 到 6 号波形为中型车车辆磁场信号，7 到 9 号波形为大型车车辆磁场信号。这一结果表明，车辆的 X 轴

信号和 Z 轴信号相比 Y 轴信号具有显著的特征，Y 轴信号大多呈现单峰波形，因为当车辆经过地磁传感器时，地磁扰动在 Y 方向上是一致的。




图 4.1 车辆磁场分割示意图

为了识别车辆类型，需要一些定量指标来提取磁信号的特征，这些指标应与信号波形具有高相关性，并且易于计算。通常，车辆信号中包括大量的数据点，为了降低数据维数并获得更好的性能，在此阶段通常使用特征提取技术^{[47][48]}。

表 4.2 车型分类特征

符号	符号名称
$X_{\max}, Y_{\max}, Z_{\max}$	最大值
X_R, Y_R, Z_R	极差
$X_{\text{mean}}, Y_{\text{mean}}, Z_{\text{mean}}$	均值
$X_{\text{var}}, Y_{\text{var}}, Z_{\text{var}}$	方差
$X_{n,\max}, Y_{n,\max}, Z_{n,\max}$	峰值个数
$X_{n,\min}, Y_{n,\min}, Z_{n,\min}$	谷值个数
$X_{p,\max}, Y_{p,\max}, Z_{p,\max}$	最大值相对位置
$X_{p,\min}, Y_{p,\min}, Z_{p,\min}$	最小值相对位置
Len	车辆磁场长度
X_{Pn}, Y_{Pn}, Z_{Pn}	正负能量比
Ev	平均能量
$X_{\text{cross}}, Y_{\text{cross}}, Z_{\text{cross}}$	过均值点个数
$X_{ApEn}, Y_{ApEn}, Z_{ApEn}$	近似熵

本文将对三轴磁传感器在三个方向上采集的信号进行特征提取。所获得的特征将被组合成一个特征集，用于描述车辆的类型信息。需要说明的是，本文所描述的信号是经过去除环境磁场处理的。虽然同一类型车辆的信号波形可能会受到车速、车载设备等因素的影响而略有不同，但这并不会对识别车辆类型的信号特征产生太大影响。本文中使用的特征如表 4.2 所示。其中，最大值可以提供信号的最大振幅这一强度信息；极差提供了信号的振幅范围信息；峰值个数和谷值个数分布表示信号中峰值和谷值的数量；最大值相对位置和最小值相对位置分布表示信号中最强和最弱的部分相对于整段车辆信号的位置信息。这些信息可以帮助识别和描述不同信号之间的局部结构差异。而均值表示信号整体的中心趋势；方差反映了信号值偏离均值的程度；车辆磁场长度反映了车辆通过传感器的时间长度；正负能量比可以反映信号的能量分布情况；平均能量表征信号的整体强度；过均值点个数表示车辆信号穿过平均线的次数；近似熵则是信号复杂度或不规则性的度量。这些信息则反映了不同信号之间的整体结构差异。在提取每个车辆的每个特征集之后，将其作为后续特征选择算法的操作对象。

在表 4.2 中， $X_{\max}$ 、 $Y_{\max}$ 、 $Z_{\max}$ 分别表示在地磁传感器 X 轴、Y 轴和 Z 轴上收集的信号最大值，同样的特征描述方法也适用于其他特征符号。如图 4.2 对部分车型分类特征进行了解释。




图 4.2 车型分类特征说明图

正能量和负能量的比值以及平均能量的计算式如式(4-7)到式(4-10)所示。

$$X_{Pn} = \frac{\sum_{B_{x,k} > 0} B_{x,k}}{\sum_{B_{x,k} < 0} B_{x,k}} \quad (4-7)$$

$$Y_{Pn} = \frac{\sum_{B_{y,k} > 0} B_{y,k}}{\sum_{B_{y,k} < 0} B_{y,k}} \quad (4-8)$$

$$Z_{Pn} = \frac{\sum_{B_{z,k} > 0} B_{z,k}}{\sum_{B_{z,k} < 0} B_{z,k}} \quad (4-9)$$

$$Ev = \frac{\sum_{k=1}^L (B_{x,k}^2 + B_{y,k}^2 + B_{z,k}^2)}{Len} \quad (4-10)$$

其中, $B_{x,k}$ 、 $B_{y,k}$ 、 $B_{z,k}$ 分别表示地磁传感器在 X、Y、Z 方向上采集到的磁场信号中第 k 个磁场感应强度值。过均值点个数特征定义为车辆信号穿过平均线的次数^[49], 在图 4.2 中该值为 2。近似熵是一种用于衡量时间序列数据复杂性的特征, 其计算方法主要有四个步骤^[50], 以 X 轴为例进行说明, 同样的原理也适用于 Y 轴和 Z 轴。

第一步, 计算向量序列。对于已知的 X 轴磁场感应强度序列 $\mathbf{B}_x = [B_{x,1}, B_{x,2}, \dots, B_{x,N}]$, 构建新的向量序列 $V_n^{m,r}$, 其中 m 是向量的长度, r 是容差阈值。构建向量的方法是选择原始序列中的连续 m 个数据点作为一个向量。

$$V_n^{m,r} = [B_{x,n}, B_{x,n+1}, \dots, B_{x,n+m-1}] \quad n = 1, 2, \dots, Len - m + 1 \quad (4-11)$$

第二步, 定义距离度量。定义向量之间的距离度量为 $C_n^{m,r}$, 用于衡量向量 $V_n^{m,r}$ 与其他所有向量之间欧氏距离的大小。其中, Π 是指示函数, 表示如果距离小于等于 r , 则记为 1, 否则为 0。

$$C_n^{m,r} = \sum_{k=1, k \neq n}^{Len-m+1} \Pi(r - \|V_n^{m,r} - V_k^{m,r}\|) \quad (4-12)$$

第三步, 计算概率和近似熵。用 $A_n^{m,r}$ 表示向量 $V_n^{m,r}$ 与其他向量 $V_k^{m,r}$ 距离小于等于 r 的概率。

$$A_n^{m,r} = \frac{C_n^{m,r}}{Len - m} \quad (4-13)$$

第四步, 计算近似熵。

$$X_{ApEn} = -\frac{1}{Len-m+1} \sum_{n=1}^{Len-m+1} \ln\left(\frac{A_n^{m,r}}{A_n^{m+1,r}}\right) \quad (4-14)$$

4.3.2 车型分类特征筛选

从数据中可以提取到大量的特征，但是，并非所有特征对于解决具体的分类问题都是必要的。部分特征可能是冗余的，它们与其他特征之间存在相关性，或者与分类任务无关^[9]。过多特征会导致过拟合、降低模型解释性等问题。解决这个问题的一种方法是特征选择，特征选择的目标是减少特征的数量，同时保留最有效的特征，以提高模型的性能和泛化能力，使其在机器学习和统计建模任务中更具有实用性。此外，由于选取的特征子集较小，计算成本和时间也会相应减少。特征选择是数据预处理的一个重要步骤，它有助于降低维度，并加快训练和推断的速度^[51]。

在特征提取过程之后，每个车辆的信号样本将由 35 个特征描述。在有限数量的样本下，特征数量较多，基于这些特征的分类器可能会面临一些挑战。因此，需要通过特征选择从所有可用的特征中筛选出最具有代表性和最相关的特征，以便用于训练分类模型。特征选择可以分为三大类：1)过滤式选择 2)包裹式选择 3)嵌入式选择^[52]。过滤式特征选择方法^[53]对特征的统计属性进行独立评估，旨在迅速筛选出与目标变量相关性较高的特征。这类方法不依赖于具体的学习算法，而是根据特征本身的特点进行选择。典型的过滤式方法包括方差阈值、互信息、卡方检验等。过滤式方法的优势在于计算速度快，适用于大规模数据集和计算资源有限的情境，但它们的缺点在于未考虑具体学习算法的信息，可能选择对某些算法不够有利的特征。另一方面，包裹式选择方法^{[54][55]}与具体学习算法紧密耦合，通过反复运行模型并调整特征子集，最终选择在模型性能上表现最好的特征组合。这类方法直接利用了学习算法的性能作为特征选择的标准，更全面地考虑了特征对具体学习算法的优化影响。典型的包裹式选择方法包括递归特征消除、前向选择和后向消除等。尽管包裹式选择方法能够提供更准确的特征子集，但其计算开销较大，适用于特征空间相对较小的情况。在过滤式和包裹式特征选择方法中，特征选择过程与学习器训练过程有明显的分别。与此不同，嵌入式选择技术是将特征选择融入到模型训练过程中，通过学习算法自身的内部机制来评估特征的重要性。典型的嵌入式技术包括 LASSO（Least Absolute Shrinkage and Selection Operator，最小绝对值收缩和选择算子）和树模型中的特征重要性评估。这类方法综合了过滤器和包装器的优点，既考虑了计算效率，又充分利用了学习算法的信息。嵌入式技术适用于中小规模数据集，对模型性能有较高要求的场景。虽然这类方法计算开销适中，但其局限性在于与具体学习算法耦合，不够通用。综合考虑三种特征选择方法的优缺点，本文提出了一种基于特征配对消除的筛选算法。该方法既具

有过滤方法的优点,又去除了特征集中的冗余特征,避免了包装器算法的高计算代价。

特征配对消除方法分为三个步骤:首先,根据决策树重要性评估,得到各个特征对车型分类的重要性排序;其次,通过计算两两特征之间的皮尔逊相关系数,对相关性较高的特征对中重要性较低的特征进行剔除;最后,进行遍历降维,筛选出准确率和效率最高的新特征集。

在建立完整的决策树后,可以根据特征在树中出现的频率、深度以及参与节点划分的次数等信息来评估每个特征的重要性,并进行排序。所述的决策树重要性评估是指通过计算不同特征的袋外误差来衡量其重要性。该方法基于袋外误差的变化,评估每个特征对模型性能的贡献,本文使用的模型是决策树模型。每棵决策树的构建都是基于随机抽样的数据集,因此会有一部分样本被排除在训练集之外,形成袋外样本。袋外误差是在袋外样本上评估模型性能的一种特征。通过对每个特征进行排列,重新计算模型在袋外样本上的误差,可以得到不同特征对袋外误差的影响。OOB PPT(Out-of-Bag Permuted Predictor Delta Error, 袋外样本置换预测误差变化)的计算式如式(4-15)所示。

$$OOB = \frac{1}{B} \sum_{b=1}^B E_b - E_{b,permuted} \quad (4-15)$$

其中, B 表示决策树的数量, E_b 表示第 b 个树在袋外样本上的误差, $E_{b,permuted}$ 表示第 b 个树在对应于某个特征排列后的袋外样本上的误差。

皮尔逊相关系数是一种衡量两个变量之间线性相关程度的统计量。本文使用皮尔逊相关系数来评估两个特征之间的相关性。当相关系数为 1 时,两个变量呈线性正相关关系;当相关系数为 -1 时,两个变量呈线性负相关关系;当相关系数接近 0 时,表示两个变量之间的线性相关性较弱。两个特征之间皮尔逊相关系数的计算式如式(4-16)所示。

$$\rho_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4-16)$$

其中, n 表示观测值的数量, $\bar{x}$ 和 $\bar{y}$ 表示两个变量的样本均值, x_i 和 y_i 表示两个变量的第 i 个观测值。在本文中,如果两个特征之间的相关性强度超过了阈值 Rt , 表明两个特征之间存在相互依赖的关系,则称这两个特征是配对的, Rt 需要在过滤冗余特征之前设置。

FPN (Feature Pairing Number, 特征对编号) 表示特征配对的数量,即每个特征

与其他特征组合形成的配对数。当特征的 FPN 较大时,说明该特征与其他特征存在较多的组合关系,即与其他特征之间的相关性较强,特征的冗余性也就越高。因此,FPN 的大小可以被视为衡量特征之间相关程度的指标。在这个特征选择算法中,对 FPN 进行统计有助于识别出冗余性较高的特征,从而通过剔除这些特征降低特征集的复杂性。每个特征的初始 FPN 为零,对于每对不同的特征,其相应特征的 FPN 值加一。本文提出的特征选择算法的核心思想是对每个特征的 FPN 进行统计,通过移除 FPN 较大的特征实现对特征集的优化。




图 4.3 冗余特征移除示意图

在决策树重要性评估阶段中,特征已经按重要程度降序排序,因此特征的重要程度越高,对应的编号越小。特征对 (m,n) 表示特征子集 F 中的两个特征,其中 m 和 n 分别是特征的索引号。特征筛选的具体步骤如下:首先,将所有成对的特征对存储在一个名为 Far 的数组中。这意味着将所有可能的特征组合成一对,以便计算它们之间的 FPN 值。第二步,从数组 Far 中选择具有最大 FPN 值的特征,并将包含该特征的特征对从数组中移除。同时,将该特征从特征子集中移除。这样做的目的是为了选择对分类性能贡献最大的特征,同时避免重复选择相关的特征对。需要注意的是,在进行特征选择时,如果有多个特征获得了最大的 FPN 值,则选择其中具有最大编号的特征。最后,重复执行上述步骤,直到数组为空。冗余特征移除示意图如图 4.3 所示。

在经过前两步筛选出的特征集合中,为了确定最优的特征组合,采用了一种穷举搜索的方法。该过程涉及以下步骤:首先,对给定的特征集,生成所有可能的特征组合,包括从当前特征集中选择一个特征、两个特征,一直到选择所有特征。然后,针对每个特征组合,建立相应的决策树模型,并使用 5 折交叉验证评估每个模型的准确

率。在评估完成后，将所有特征组合按照准确率降序排序，以找到准确率最高的特征组合。如果有多个特征组合具有最大准确率，则进一步比较它们的特征数量，选择特征数量最少的作为最优特征组合。

4.4 车型分类算法设计

4.4.1 车型分类算法选择

在机器学习中，分类问题占据着重要地位，而选择分类器通常取决于任务的性质、数据的特征以及模型的需求。SVM、KNN、决策树和 SoftMax 回归都是常见的分类算法，各自具有特定的优势和适用场景。本节旨在通过比较这四种分类器，找到最适合本文任务的分类器。

SVM（Support Vector Machine，支持向量机）在多特征的多分类场景中有其独特的优缺点。首先，SVM 在高维空间中表现良好，适用于处理具有多个特征的数据集。其优势之一是能够处理非线性关系，通过使用核函数将数据映射到高维空间，使得原始空间中线性不可分的问题也能够被有效解决。然而，SVM 的计算复杂度随着特征数量的增加而显著上升，在大规模数据集上表现不佳。此外，SVM 对于超参数的选择相对敏感，需要精确调整以获得最佳性能。在多分类问题中，SVM 通常采用 One-vs-One 或 One-vs-Rest 的策略，这可能导致在某些情况下的计算开销较大。

KNN（K-Nearest Neighbors，K-最近邻）是一种简单而直观的算法，易于理解和实现。它不需要对数据进行训练，而是通过存储训练数据集的方式直接进行预测。对于多特征的多分类问题，KNN 能够自然地处理复杂的决策边界，适用于非线性关系的情况。然而，KNN 的主要缺点之一是计算复杂度较高，尤其是在高维特征空间中。对于每个预测样本，需要计算与所有训练样本之间的距离，并选择最近的 K 个样本，这在大规模数据集上可能变得非常低效。此外，KNN 对异常值和噪声敏感，因为它的预测依赖于邻近的样本。在存在不平衡类别的情况下，KNN 可能偏向于具有更多样本的类别。另外，KNN 的性能也受到 K 值选择的影响。较小的 K 值可能导致模型对噪声敏感，而较大的 K 值可能导致模型过于平滑，忽略了局部的细节。因此，KNN 需要精确选择 K 值以获得最佳性能。

决策树模型易于理解和解释，能够处理多类别问题，并且对于包括数值型和分类型特征的混合数据类型具有较好的适应性。此外，决策树在处理缺失值时表现较为鲁棒，不需要对数据进行过多的预处理。然而，决策树容易过拟合，特别是在复杂的树结构中，可能会过度匹配训练数据，而在新数据上表现不佳。为了缓解过拟合，可以通过剪枝等技术来调整决策树的复杂度。另外，输入特征的微小变化有可能会对决策树造成较大的影响，这使得模型对数据的噪声敏感。在高维数据集上，决策树可能不

如其他算法表现出色，因为其划分规则的增加可能导致模型过于复杂。当将决策树模型可视化时，可以清晰地看到决策路径，其中根结点和叶子结点之间的分支是决策结点，由特定特征的值划分决定。通过对误分类数据的单独分析，考虑改变决策结点的计算方式来提高分类的准确率。一个基本思想就是将不同的特征组合成一个特征向量，本质就是基于已有特征集合生成新的、更精确、更全面的特征，并将其作为决策结点，而不是通过计算每个特征的信息熵来确定唯一的特征作为决策结点。该问题的难点在于对各个特征进行加权时的权重选择。

SoftMax 回归是一种概率化的分类器，它输出每个类别的概率分布，而不仅仅是单一的类别标签。在使用输出概率作为分类器的输出时，通常会选择具有最高概率的类别作为最终的预测标签，这使得 SoftMax 回归的输出结果更容易解释和理解。其次，SoftMax 回归在处理高维特征空间和非线性关系方面同样表现出色，通过学习每个特征的权重，能够适应各种复杂的数据结构。与决策树相比，SoftMax 回归模型在一定程度上也具有可解释性，特别是在分析特征权重时。决策树通过可视化决策路径展示特征的重要性，而 SoftMax 回归则通过学习每个特征的权重来评估特征的重要性。在特征加权方面，SoftMax 回归能够通过学习得到每个特征的权重，而不需要手动设置权重，这有助于更好地适应数据的复杂关系。

对比四种分类器，本文选择 SoftMax 回归作为车型分类分类器的原因之一是其灵活性和概率输出的特性。SoftMax 回归通过输出概率分布，可以提供关于每个类别的不确定性信息。其概率输出和适用于梯度下降的特性使得 SoftMax 回归在大规模数据集上更具可扩展性。此外，SoftMax 回归模型通常能够在大规模数据集上表现较好，能够处理类别间的相关性，对于复杂的数据结构有更好的适应性。

4.4.2 基于梯度下降算法确定参数值

SoftMax 回归用于解决多类别分类问题，其中每个样本属于且仅属于一个类别。SoftMax 回归模型通过线性变换将输入特征映射到未归一化的类别向量 $\mathbf{z} \in R^c$ ，其中 c 表示类别数量，本文的案例中 $c = 3$ 。令输入特征为 $\mathbf{f} \in R^g$ ，其中 g 表示特征的维度；令权重矩阵为 $\mathbf{w} \in R^{g \times c}$ ；令偏置 $\mathbf{b} \in R^c$ ，表示线性模型中的一个常数项。SoftMax 回归说明示意图如图 4.4 所示。

图 4.4 中最后一步的 SoftMax 函数用于将未归一化的类别分数 $\mathbf{z}$ 转换为每个类别的概率，其计算方法如式(4-19)所示。

$$\text{SoftMax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^c e^{z_j}} \quad (4-17)$$

其中， z_i 表示未归一化类别向量中的第 i 个元素。SoftMax 函数通过指数化并归一化

$\mathbf{z}$ ，确保每个类别的概率在 $[0,1]$ 范围内，且概率总和为 1。




图 4.4 SoftMax 回归说明示意图

在使用 SoftMax 回归进行多分类时，需要定义一个代价函数来评估模型的准确性。SoftMax 回归常用交叉熵损失函数来衡量模型输出概率分布与实际标签的差异。当正确类别的概率分布越接近于 1 时，交叉熵损失越小，损失函数的目标是最小化所有样本的平均损失。交叉熵损失函数的计算式如式(4-18)所示。

$$L(y_i, \hat{y}_i) = -\sum_{j=1}^c \mathbb{I}(y_i = j) \log(\hat{y}_{i,j}) \quad (4-18)$$

其中， $\mathbb{I}$ 是指示函数，表示如果样本 y_i 的类别标签为 j 则为 1，否则为 0； $\hat{y}_{i,j}$ 表示模型对样本 y_i 属于类别 j 的预测概率，其计算式如式(4-19)所示。

$$\hat{y}_{i,j} = \frac{e^{\mathbf{f}_i \mathbf{w}_j}}{\sum_{k=1}^c e^{\mathbf{f}_i \mathbf{w}_k}} \quad (4-19)$$

其中， $\mathbf{f}_i$ 表示第 i 组样本 y_i 输入的特征集， $\mathbf{w}_j$ 表示权重矩阵第 j 列。最终，整个模型的损失函数是对所有样本的交叉熵损失的平均值，其计算式如式(4-20)所示。

$$J(\mathbf{w}, \mathbf{b}) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{y}_i) \quad (4-20)$$

在 SoftMax 回归中存在参数集冗余的问题，即假设从权重向量 $\mathbf{w}_j$ 中减去向量 $\boldsymbol{\phi}$ ，得到式(4-21)。

$$\begin{aligned}
 \hat{y}_{i,j} &= \frac{e^{\mathbf{f}_i(\mathbf{w}_j - \boldsymbol{\phi})}}{\sum_{k=1}^c e^{\mathbf{f}_i(\mathbf{w}_k - \boldsymbol{\phi})}} \\
 &= \frac{e^{\mathbf{f}_i \mathbf{w}_j} e^{-\mathbf{f}_i \boldsymbol{\phi}}}{e^{-\mathbf{f}_i \boldsymbol{\phi}} \sum_{k=1}^c e^{\mathbf{f}_i \mathbf{w}_k}} \\
 &= \frac{e^{\mathbf{f}_i \mathbf{w}_j}}{\sum_{k=1}^c e^{\mathbf{f}_i \mathbf{w}_k}}
 \end{aligned} \tag{4-21}$$

式(4-21)表明从权重向量中减去常数向量 $\boldsymbol{\phi}$ 并不会改变模型对输入类别的预测，该现象说明 SoftMax 回归模型是过参数化的，这种过参数化的特性可能导致模型的不稳定性，并且在优化过程中会出现多个局部最优解。因此需要加入权重衰减项来更新模型参数，以解决 SoftMax 回归的参数冗余所带来的数值问题，该方法可以惩罚过大的参数值。添加权重衰减项后的损失函数的计算式如式(4-22)所示。

$$J(\mathbf{w}, \mathbf{b}) = \frac{1}{I} \sum_{i=1}^I L(y_i, \hat{y}_i) + \frac{\lambda}{2} \sum_{m=1}^g \sum_{n=1}^c w_{mn}^2 \tag{4-22}$$

其中， $\lambda > 0$ 表示权重衰减参数， I 表示样本数量。通过引入权重衰减项，损失函数变成了严格的凸函数，这意味着模型在优化过程中会收敛到一个唯一的参数解。

梯度下降算法是训练机器学习模型中用于最小化损失函数的一种常见方法，基于式(4-22)使用梯度下降算法来最小化损失函数，求得最佳的模型系数。在梯度下降的过程中，首先通过计算损失函数关于模型系数的梯度，得到每个系数的变化方向。然后，通过更新当前的模型系数，使得损失函数减小。反复进行该过程，直到损失函数达到最小值，或者变化足够小。这时，模型系数的值即为使得损失函数最小化的最佳解。梯度是一个向量，包含损失函数对每个系数的偏导数。通过更新模型系数，可以沿着梯度的反方向逐步逼近最优解。更新的规则表达式如式(4-23)所示。

$$\theta = \theta - \alpha \frac{\partial J(\mathbf{w}, \mathbf{b})}{\partial \theta} \tag{4-23}$$

其中， α 表示学习率，控制模型参数在每次迭代中的更新步长。如果学习速率过大，可能导致无法收敛；如果学习速率过小，可能收敛到局部最小值而非全局最小值。梯度下降算法的整个过程就是一种基于局部梯度信息的搜索和优化策略，通过这样的迭代过程逐步优化模型，使其在训练数据上取得更好的拟合效果。

4.5 实验测试结果与性能分析

4.5.1 实验场景介绍

本文在 21~25°C 的温度条件下，分别在正常交通和低速拥堵交通场景下进行了实验测试。测试的车辆速度分别为 30~40km/h 的正常交通和 10~15km/h 的低速拥挤的交通。传感器节点被放置在道路一侧，距离车辆约 0.4~0.8 米，如图 4.5 所示。



图 4.5 实验测试场景图

AMR 磁传感器在 3~5 米的传感范围内工作良好，而西安城市道路的车道宽度约为 3.5 米，正常情况下车辆宽度超过 2 米，因此其他车道引起的影响可以通过第三章的邻道干扰排除算法进行剔除，本实验主要关注目标车道车辆的车型分类。本文根据车辆的尺寸和结构将车辆类型分为三大类：小型车，中型车和大型车。本次实验共收集了 1370 组车辆信号，其中，小型车 548 辆，中型车 480 辆，大型车 342 辆。

4.5.2 测试结果分析

本文基于实验收集的 1370 组车辆信号对车型分类算法进行了测试，所述方案流程图如图 4.6 所示。




图 4.6 车型分类方案流程图

首先，根据式(4-7)到式(4-14)为每个车辆信号计算 35 个信号特征。其次，根据式(4-15)来计算特征的袋外误差变化值评估每个特征的重要性，计算结果如表 4.3。

表 4.3 车型分类特征袋外误差变化值

特征名称	X 轴	Y 轴	Z 轴
最大值	0.4763	0.3797	0.3487
极差	0.3693	0.3558	0.4533
均值	0.2879	0.4167	0.7734
方差	0.4573	0.3792	0.2913
峰值个数	0.1966	0.6362	0.2766
谷值个数	0.0847	0.1423	0.2886
最大值相对位置	0.5258	0.3157	0.1244
最小值相对位置	0.1177	0.1855	0.2084
车辆磁场长度	0.3412		
正负能量比	0.2102	0.2495	0.1033
平均能量	0.5485		
过均值点个数	0.1397	0.1685	0.1302
近似熵	0.3733	0.3037	0.5576

根据式(4-16)计算特征对之间的皮尔逊相关系数,一般认为 $|\rho_{x,y}| \geq 0.8$ 时两个特征高度相关, $0.5 \leq |\rho_{x,y}| < 0.8$ 时两个特征中度相关, $0.3 \leq |\rho_{x,y}| < 0.5$ 时两个特征低度相关, $|\rho_{x,y}| < 0.3$ 时两个特征基本不相关。本文将相关系数阈值 Rt 设置为 0.5, 如果两个特征之间的相关性强度超过了阈值 Rt , 则称这两个特征是配对的, 并对每个特征的特征配对数量 FPN 进行统计, 统计结果如表 4.4 所示。最终, 使用穷举搜索得到的最优特征组合为 $\mathbf{F} = \{Z_{mean}, Y_{n,max}, X_{p,max}, Z_{ApEn}\}$ 。

表 4.4 特征配对数量统计

特征名称	X 轴	Y 轴	Z 轴
最大值	8	5	7
极差	11	9	11
均值	2	1	1
方差	10	8	10
峰值个数	1	1	2
谷值个数	1	1	2
最大值相对位置	1	1	1
最小值相对位置	5	2	0
车辆磁场长度	9		
正负能量比	2	2	1
平均能量	8		
过均值点个数	0	0	0
近似熵	2	2	2




图 4.7 损失函数值变化图

确定特征集之后，需要对 SoftMax 函数进行参数估计。在采用梯度下降算法得到各个特征值关于每个车型的 SoftMax 函数时，本文设置的权重衰减参数 $\lambda = 0.004$ ，学习率 $\alpha = 0.1$ ，最大迭代次数为 700。得到的损失函数值变化如图 4.6 所示，从中可以看出梯度下降算法在迭代 200 次之后已经基本收敛。

使用梯度下降算法求得进行车型类型识别时对特征值进行加权融合所采用的权重矩阵 $\mathbf{w}$ 和偏置 $\mathbf{b}$ 如式(4-24)和式(4-25)所示。

$$\mathbf{w} = \begin{bmatrix} 0.7851 & -0.1160 & -0.6813 \\ 2.6738 & -2.7922 & 0.1192 \\ -0.1781 & -1.4613 & 1.6388 \\ -0.3735 & 0.4989 & -0.1294 \end{bmatrix} \quad (4-24)$$

$$\mathbf{b} = [-0.2094 \quad -1.3253 \quad 1.5286] \quad (4-25)$$

为了得到可靠的分类结果，将数据集分为两部分，70%的数据用于训练模型，剩余的 30%用作独立的测试集。接下来，在特征子集 $\mathbf{F}$ 上使用不同分类器的模型，利用测试集对模型性能进行了验证，SVM，KNN，决策树和 SoftMax 回归的分类准确率如表 4.5 所示。

表 4.5 车型分类准确率

类型 分类算法	小型车	中型车	大型车	总计
SVM	89.09%	90.28%	92.23%	90.29%
KNN	86.06%	82.64%	93.20%	86.65%
决策树	92.12%	92.36%	92.23%	92.23%
SoftMax 回归	96.97%	95.14%	100%	97.09%

在很多研究中，车辆检测节点使用的传感器数量是一个或者两个，两者都有优势和缺点。使用两个磁传感器提供了车辆长度的重要特征，而使用单个磁传感器降低了成本。此外，不同文献提取的车辆信号特征也不同。例如，Chen 等人^[56]引入 Mel 频率倒谱系数对车辆磁信号进行分析，并将其作为车辆特征提取出来，分别用磁信号的倒谱、帧能量和间隙倒谱表示。Kaewkamnerd 等人^[57]详述的工作中使用两个 3 轴 AMR 传感器来收集车辆的磁场扰动信号，并以车辆长度、平均能量和峰数作为车型分类的特征。Yang 等人^[33]提出使用单个 3 轴 AMR 传感器来提取信号的持续时间、信号能

量、信号的平均能量、X 轴信号的正负能量比和 Y 轴信号的正负能量比作为车型分类的特征。其他类似的方法也提出了信号的其他特征，如提取平均垂直磁高度，微分能量，方差，最大值以及极值的数量等^{[17][49]}。本文将一个地磁传感器部署车道一侧的车道线上，不会影响正常的交通并且便于维护，同时基于单地磁传感器的检测方法不存在多个地磁传感器的对时操作，能够获取更加实时的车型信息。本文使用的地磁传感器成本较低且不受天气影响，便于大规模部署，能够解决摄像机、分布式光纤声学传感器等传感器成本较高并且受天气影响严重的问题。本文在搭载地磁传感器的感知节点中内置了计算量低的车辆磁场特征计算算法以及大中小三类车型的区分模型，可以实现最大车均延误小于 100s 且最大排队时间指数小于 1.5 的轻度拥堵情况下大型车、中型车、小型车的准确区分，能够解决现有车型分类算法计算量高的问题。

4.6 本章小结

基于地磁传感器的车型分类可以有效地应用于智能交通，实现交通的智能管理。利用具有代表性的车辆信号特征是准确进行车辆分类的前提和保证。本章采用单个三轴地磁传感器采集车辆信号，并从车辆信号中提取大量特征。为了获得一组简单的特征，而不损失分类精度，本文提出了一种基于特征配对消除的筛选算法。此外，选择正确的分类器对于具有高分类精度的模型也至关重要。本文比较了三种常见的分类模型：SVM，KNN，决策树和 SoftMax 回归。实验结果表明，SoftMax 回归的性能最好，分类准确率达到 97%。

第五章 总结与展望

在当今城市交通快速发展的背景下，智慧交通系统作为推动交通管理与服务升级的关键因素备受瞩目。随着智能感知技术的不断进步，地磁传感器作为车辆信息感知系统的重要组成部分，在监测交通流量、保障道路安全和改善交通效率方面扮演着关键角色。然而，在双车道场景下，相邻车道车辆的检测会对目标车道车辆的准确检测造成干扰。为此，创新性的邻道干扰排除算法成为提高地磁传感器车辆检测准确性和可靠性的关键。

本文研究的首要任务是设计状态机车辆检测算法及车辆检测系统，并在此基础上深入研究双车道交通场景下的邻道干扰问题。通过对地磁传感器布置和车辆检测系统的特性分析，揭示了相邻车道车辆对准确车辆数量获取的影响。为了解决这一问题，本文从车辆的磁偶极子模型出发，引入多磁偶极子车辆模型，并通过差分进化算法确定模型参数。通过模型仿真和理论分析，提取了用于邻道干扰排除的磁场特征，并设计了有效的投票机制，成功实现了双车道交通场景下的邻道干扰排除。实验结果验证了所设计算法在提高目标车道车辆检测精度方面的有效性，实验结果表明该方法可以修正 98% 的相邻车道误检测，相较于 Taghvaeeyan 等人提出的算法误检率降低了 7%，相较于张等人提出的算法误检率降低了 11%。

在解决邻道干扰问题的基础上，本文进一步关注了能够准确检测目标车道车辆的地磁传感器，在此条件下进行了车型分类问题的深入分析。由于地磁传感器采集到的三轴磁场数据受到环境磁场和车辆引起的磁场扰动的影响，本文提出了地磁环境基线更新方法。通过去除地磁环境基线，成功提取了车辆引起的磁场扰动。在此基础上，对不同车辆类型引起的磁场扰动波形进行了详细分析，并提取和筛选了适用于车型分类的特征集。通过这些特征，设计了基于 SoftMax 回归的车型分类算法，并通过实验证明该算法在车型分类上具有较高的精度，实验结果表明该方法的车型分类准确率能达到 97.09%。

总体而言，本文通过对智慧交通系统中地磁传感器的研究，提出并验证了一种有效的邻道干扰排除和车型分类方法。该方法在提高车辆检测准确性和实现车型分类方面取得了显著成果。然而，未来的研究仍可进一步优化算法性能、扩展适用场景，并考虑更多实际交通场景的复杂性。在现有相关成果的基础上，本文针对智慧公路的邻道干扰问题与车型分类问题进行了研究，但还有许多不足之处有待改进：

(1) 本文提出的双车道场景车辆检测方案在正常车流情况下表现良好，但在车流密度较大或者拥堵情况下，该方案的准确率可能会有所降低。鉴于当前提出的双车道场景车辆检测方案在车流密度较大以及车型多样性较高的情况下可能存在一定的局

限性，因此需要提高车辆检测方案的适用性，使其在更广泛的实际场景中发挥作用。另外需要将车辆检测方案扩展到更多车道的场景并进行测试验证。

(2)本文提出的车型分类算法能够将机动车分为大、中、小三大类，其中车型分类可以更细致，不仅限于大、中、小型车，以提高系统对不同车型的辨识能力。其次，需要考虑更多的环境因素对地磁传感器数据的影响，以提高系统在复杂道路条件下的鲁棒性。此外，算法的实时性和效率也是一个需要关注的方面，特别是在实际交通场景中，快速准确地识别车辆类型对于智慧交通系统至关重要。总体而言，对于这项研究，可以考虑进一步细化车型分类、考虑更多环境因素、提高实时性和效率，以使该技术更加实用和可靠。

在此基础上，上述改进将有望为智慧交通系统的发展提供更为深入和全面的支持。

参考文献

- [1] H. Lin, C. Tang. Analysis and Optimization of Urban Public Transport Lines Based on Multiobjective Adaptive Particle Swarm Optimization[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(9): 16786-16798.
- [2] 中共中央国务院. 国家综合立体交通网规划纲要[EB]. <https://www.gov.cn/gongbao>. [2021].
- [3] 交通运输部. 关于科技创新驱动加快建设交通强国的意见[EB]. <https://www.gov.cn/zhengce>. [2021].
- [4] Q. Yuan, Li J, Zhou H, et al. Cross-Domain Resource Orchestration for the Edge-Computing-Enabled Smart Lane[J]. IEEE Network, 2020, 34(5): 60-67.
- [5] X. Ma, X. Hao, H. Chen. Fuzzy Neural Network-Based Assessment of Lane Traffic Situations Using Extracted Information Obtained from Optical High-Resolution Satellite Remote Sensing Images[C] // IEEE International Geoscience and Remote Sensing Symposium, 2020, 148-151.
- [6] C. Chen, B. Liu, S. Wan, et al. An Edge Traffic Flow Detection Scheme Based on Deep Learning in an Intelligent Transportation System[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(3): 1840-1852.
- [7] B. Gong, Z. Xu, C. Lin, et al. Heterogeneous Traffic Flow Detection Using CAV-Based Sensor With I-GAIN[J]. IEEE Access, 2023, 11: 32616-32627.
- [8] Mokaddem Y E, Jawab F. Researches and applications of Intelligent Transportations Systems in urban area: systematic literature review[J]. Journal of Engineering and Applied Sciences, 2019, 14(3): 639-652.
- [9] F. Zhu, Y. Lv, Y. Chen, et al. Parallel Transportation Systems: Toward IoT-Enabled Smart Urban Traffic Control and Management[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(10): 4063-4071.
- [10] K. F. Hussain, M. Afifi, G. Moussa. A Comprehensive Study of the Effect of Spatial Resolution and Color of Digital Images on Vehicle Classification[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20: 1181-1190.
- [11] Y. Yao, D. Wu, J. Yang, et al. Analyzing the Effects of Rainfall on the Urban Traffic Congestion Bottlenecks by Using Floating Car Data[C] // IEEE International Geoscience and Remote Sensing Symposium, 2019, 943-946.
- [12] Cao, Xu, Xu. Real-Time Calibration of Magnetometers Using the RLS/ML Algorithm[C] // Sensors, 2020, 20(2): 535.

- [13] X. Wu, S. Song, J. Wang. Calibration-by-Pivoting: A Simple and Accurate Calibration Method for Magnetic Tracking System[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-9.
- [14] J. Zhao. A Non-Modulated Triaxial Magnetic Field Compensation Method for Spin-Exchange Relaxation-Free Magnetometer Based on Zero-Field Resonance[J]. IEEE Access, 2019, 7: 167557-167565.
- [15] Liu M, Hua W, Wei Q. Vehicle detection using three-axis AMR sensors deployed along travel lane markings[J]. Iet Intelligent Transport Systems, 2017, 11: 581-587.
- [16] Y. Liu, L. Zheng. Research of Anti-Interference Technology Based on Magnetic Field Variation of Vehicle[C] // International Symposium on Computational Intelligence and Design, 2015, 397-400.
- [17] S. Taghvaeeyan, R. Rajamani. Portable Laneside Sensors for Vehicle Counting, Classification, and Speed Measurement[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(1): 73-83.
- [18] M. Ariannik, A. Rezaei-Zare, P. Werle. Processing Magnetometer Signals for Accurate Wide-Area Geomagnetic Disturbance Monitoring and Resilience Analysis[J]. IEEE Transactions on Power Delivery, 2021, 36(4): 2550-2558.
- [19] G. Li. Multitype Geomagnetic Noise Removal via an Improved U-Net Deep Learning Network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-12.
- [20] Tanimoto J, An X. Improvement of traffic flux with introduction of a new lane-change protocol supported by Intelligent Traffic System[J]. Chaos Solitons & Fractals, 2019, 122: 1-5.
- [21] Y. Feng, G. Mao, B. Chen, et al. MagMonitor: Vehicle Speed Estimation and Vehicle Classification Through A Magnetic Sensor[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 1311-1322.
- [22] H. Liu, J. Ma, T. Xu, et al. Vehicle Detection and Classification Using Distributed Fiber Optic Acoustic Sensing[J]. IEEE Transactions on Vehicular Technology, 2020, 69(2): 1363-1374.
- [23] R. Theagarajan, N. S. Thakoor, B. Bhanu. Physical Features and Deep Learning-based Appearance Features for Vehicle Classification from Rear View Videos[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(3): 1096-1108.
- [24] E. Odat, J. S. Shamma, C. Claudel. Vehicle Classification and Speed Estimation Using Combined Passive Infrared/Ultrasonic Sensors[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(5): 1593-1606.
- [25] N. Shvai, A. Hasnat, A. Meicler, et al. Accurate Classification for Automatic Vehicle-Type Recognition Based on Ensemble Classifiers[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(3): 1288-1297.

- [26] J. Shi, Z. Li, Y. Sui, et al. Low-Temperature-Drift Design of Fluxgate Sensors for Geomagnetic Observation Based on the Two-Stage Magnetic Field Adjustment Method[J]. IEEE Sensors Journal, 2023, 23(20): 24393-24403.
- [27] Wang Q, Zheng J, Xu H, et al. Laneside magnetic sensor system for vehicle detection in urban environments[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(5): 1365-1374.
- [28] W. Balid, H. Tafish, H. H. Refai. Intelligent Vehicle Counting and Classification Sensor for Real-Time Traffic Surveillance[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(6): 1784-1794.
- [29] K. Wang, H. Xiong, J. Zhang, et al. SenseMag: Enabling Low-Cost Traffic Monitoring Using Noninvasive Magnetic Sensing[J]. IEEE Internet of Things Journal, 2021, 8(22): 16666-16679.
- [30] I. Ullah, J. Youn, Y. -H. Han. Multisensor Data Fusion Based on Modified Belief Entropy in Dempster-Shafer Theory for Smart Environment[J]. IEEE Access, 2021, 9: 37813-37822.
- [31] F. Wang. Transportation 5.0: The DAO to Safe, Secure, and Sustainable Intelligent Transportation Systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(10): 10262-10278.
- [32] E. S. Lee, S. Y. Jeong. A Uniformly Wide-Range Distributed DC Magnetic Generator Based on Residual Magnetic Field for Motion Measurement[J]. IEEE Journal of Emerging and Selected Topics in Power Electronics, 2023, 11(5): 5092-5101.
- [33] B. Yang, Y. Lei. Vehicle Detection and Classification for Low-Speed Congested Traffic With Anisotropic Magnetoresistive Sensor[J]. IEEE Sensors Journal, 2015, 15(2) 1132-1138.
- [34] 交通运输部. JTG-B01-2014. 公路工程技术标准[S]. 北京: 交通运输部公路局, 2014.
- [35] J. Wang, Y. Shen, J. Gao, et al. Magnetic moment direction estimation based on magnetic anomaly signature analysis[C] // IEEE International Instrumentation and Measurement Technology Conference, 2020, 1-5.
- [36] S. T. Spantideas, A. E. Giannopoulos, N. C. Kapsalis, et al. A Deep Learning Method for Modeling the Magnetic Signature of Spacecraft Equipment Using Multiple Magnetic Dipoles[J]. IEEE Magnetism Letters, 2021, 12:1-5.
- [37] F. Bönsel, A. Müller, R. Psiuk. A Model for Multiple Metal Spheres in Oscillating Magnetic Fields Using Displaced Dipoles[J]. IEEE Transactions on Magnetism, 2022, 58(10): 1-10.
- [38] N. Wahlström, F. Gustafsson. Magnetometer Modeling and Validation for Tracking Metallic Targets[J]. IEEE Transactions on Signal Processing, 2014, 62(3): 545-556.
- [39] M. Ratchagit, H. Xu. Parameter Identification of Stochastic Delay Differential Equations Using Differential Evolution[C] // 2022 37th International Technical Conference on Circuits/Systems, Computers and Communications, 2022, 1-3.
- [40] Z. Zhang, Y. Cai, D. Zhang. Solving Ordinary Differential Equations With Adaptive Differential

- Evolution[J]. IEEE Access, 2020, 8: 128908-128922.
- [41] Z. Yan, S. Sheng-kai, L. Yue, et al. Sonar echo signal processing based on Convolution Blind source separation[C] // 2020 IEEE 3rd International Conference on Information Communication and Signal Processing, 2020, 130-134.
- [42] S. Namitha, J. Prathibha, A. A. Kumar, et al. Prediction of Movie Categories Using Randomized Sequences with Machine Learning[C] // 2023 4th IEEE Global Conference for Advancement in Technology, 2023, 1-5.
- [43] F. K. Alarfaj, I. Malik, H. U. Khan, et al. Credit Card Fraud Detection Using State-of-the-Art Machine Learning and Deep Learning Algorithms[J]. IEEE Access, 2022, 10: 39700-39715.
- [44] M. Habib, Z. Wang, S. Qiu, et al. Machine Learning Based Healthcare System for Investigating the Association Between Depression and Quality of Life[J]. IEEE Journal of Biomedical and Health Informatics, 2022, 26(5): 2008-2019.
- [45] 张君. 基于地磁的智能交通车检系统的研究[D]. 杭州: 杭州电子科技大学, 2013.
- [46] 中华人民共和国公安部. GA-802-2019. 道路交通管理机动车类型[S]. 北京: 公安部交通管理科学研究所, 2019.
- [47] X. Zhang, H. Huang. Vehicle Classification Based on Feature Selection With Anisotropic Magnetoresistive Sensor[J]. IEEE Sensors Journal, 2019, 19(21): 9976-9982
- [48] H. R. Al Ghayab, Y. Li, S. Siuly, et al. A feature extraction technique based on tunable Q-factor wavelet transform for brain signal classification[J]. Journal of Neuroscience Methods, 2019, 312: 43–52.
- [49] H. Dong, X. Wang, C. Zhang, et al. Improved robust vehicle detection and identification based on single magnetic sensor[J]. IEEE Access, 2018, 6 5247–5255.
- [50] H. Zhang. Analysis and Comparison of Permutation Entropy, Approximate Entropy and Sample Entropy[C] // 2018 International Symposium on Computer, Consumer and Control, 2018, 209-212.
- [51] M. Aladeemy, S. Tutun, M. T. Khasawneh. A new hybrid approach for feature selection and support vector machine model selection based on self-adaptive cohort intelligence[J]. Expert Systems with Applications, 2017, 88: 118-131.
- [52] M. S. S. Sumi, A. Narayanan. Improving Classification Accuracy Using Combined Filter+Wrapper Feature Selection Technique[C] // 2019 IEEE International Conference on Electrical, Computer and Communication Technologies, 2019, 1-6.
- [53] Y. Xiao, T. Liu. Filtering Feature Selection Algorithm based on Fusion Strategy[C] // 2023 2nd Conference on Fully Actuated System Theory and Applications, 2023, 675-680.

- [54] A. Nugroho, A. Z. Fanani, G. F. Shidik. Evaluation of Feature Selection Using Wrapper For Numeric Dataset With Random Forest Algorithm[C] // 2021 International Seminar on Application for Technology of Information and Communication, 2021, 179-183.
- [55] M. A. Thanoon, M. J. M. Zedan, A. N. Hameed. Feature Selection Based on Wrapper and Information Gain[C] // 2019 1st AL-Noor International Conference for Science and Technology, 2019, 32-37.
- [56] X. Chen, X. Kong, M. Xu, et al. Lane Vehicle Detection and Classification Using Magnetic Field Measurement[J]. IEEE Access, 2019, 7: 52622-52633.
- [57] S. Kaewkamnerd, R. Pongthornseri, J. Chinrungrueng, et al. Automatic vehicle classification using wireless magnetic sensor[C] // 2009 IEEE International Workshop on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications, 2009, 420-424.

致谢

文末搁笔，忽觉岁短。

桃李不言，下自成蹊。首先我要感谢我的导师，毛国强老师有着严谨的教学态度，严密的逻辑思维，丰富的学科知识，以及负责任的工作态度让我在学习和做人方面都受益匪浅。这三年，毛老师不仅在专业上给予了我很大的帮助，同时也教会了我很多做事的道理，感恩毛老师的教诲，愿毛老师桃李芬芳、教泽绵长。

焉得谖草，言树之背。我要特别感谢我的父母和家人，远行的孩子，父母总是牵挂。三年求学之路，使我不得常归家，也是这几年，父母年龄大了，我也学会了照顾他人。所爱隔山海，山海皆可平，同样的感谢我的男朋友。我的研究生生涯离不开父母和男朋友的支持，感谢我的家人一直在背后默默地守护与支持，也是他们给予我的爱与关怀，使我能从中不断汲取能量、勇毅前行。

独学而无友，则孤陋而寡闻。我要感谢我的同门，感谢同组的贺润森师兄、程庆伟师兄、同届的柳文崇、杨君怡师弟、黄研师弟、毛健强师弟、刘畅师弟，依然记得在学校北门测数据吃红薯板栗的瞬间；记得在 310 会议室讨论问题的日夜；记得在学校散步时头顶的一轮弯月。感谢同一实验室的李治明师兄、付天烜博士、孟凯婷师妹、殷圣师弟、张帅师弟，记得我们聚餐时举杯共饮的时刻；记得我们在树下互相拍照留念时时快门按下的咔嚓声。无数的美好记忆在分别时快速地在脑海中飞速闪过，纵有千般不舍，依然要互诉珍重，唯愿待到江南好风景时，我与君又能花下相逢。

以梦为马，不负韶华。最后我想感谢虽然不够聪明但始终尽力去坚持、去热爱、去保持乐观的自己。一路走来有欣喜有失落、有欢悦有孤寂，感谢自己坚持不懈，努力向着目标前进；感谢自己能接受不完美的自己，尽情纵歌无谓过往；感谢自己能够成为自己最好的朋友，黑夜残灯亦有孤影相伴。

祝毕业快乐，谨以此文，献给一路繁花。

作者简介

1. 基本情况

向倪竺，女，四川成都人，1999年9月出生，西安电子科技大学通信工程学院通信工程专业2021级硕士研究生。

2. 教育背景

2017.09~2021.07 辽宁大学，本科，专业：电子信息科学与技术

2021.09~2024.07 西安电子科技大学，硕士研究生，专业：信息与通信工程

3. 攻读硕士学位期间的研究成果

3.1 申请(授权)专利

- [1] 毛国强, 向倪竺, 惠一龙, 柳文崇. 基于单个地磁传感器的车型分类检测方法: 中国, 专利号: 202310454223.4, 申请日期: 2023年4月25日.
- [2] 毛国强, 柳文崇, 向倪竺, 任效江. 一种基于单地磁传感器的地磁差分车辆检测方法及系统: 中国, 专利号: 202410331904.6, 申请日期: 2024年3月22日.
- [3] 毛国强, 贺润森, 惠一龙, 程庆伟, 向倪竺, 柳文崇. 基于地磁传感器的公路异常停车检测方法: 中国, 专利号: 202310249500.8, 申请日期: 2023年3月15日.

3.2 参与科研项目及获奖

- [1] 国家重点研发计划项目, 高速公路智能车路协同系统集成应用(2019YFB1600102), 2020.01-2022.12, 已结题。
- [2] 第八届中国国际“互联网+”大学生创新创业大赛. 产业赛道省级金奖. 获奖项目: 惊鸿路网—智能车路协同数据服务提供者, 获奖日期: 2022年8月。
- [3] 国家自然科学基金重点支持项目, 车联网环境的智能汽车多模式高精度融合定位(U21A20446), 2022.01-2025.12。